

**RANCANG BANGUN SISTEM REKOMENDASI
RESEP MASAKAN INDONESIA BERDASARKAN
KETERSEDIAAN BAHAN MENGGUNAKAN
ALGORITMA *ARTIFICIAL NEURAL NETWORK* (ANN)**

PROPOSAL PENELITIAN

Oleh:

Muhamad Rifqi Salim
10222089



**PROGRAM STUDI INFORMATIKA
SEKOLAH TINGGI TEKNOLOGI CIPASUNG
TASIKMALAYA
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	iv
DAFTAR GAMBAR	v
DAFTAR ISTILAH	vi
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Posisi Penelitian.....	3
1.3 Rumusan Masalah.....	6
1.4 Tujuan Penelitian.....	6
1.5 Batasan Masalah.....	7
1.6 Manfaat Penelitian	7
1.6.1 Aspek Teoretis.....	8
1.6.2 Aspek Praktis	8
1.7 Sistematika Penulisan.....	8
BAB II LANDASAN TEORI	10
2.1. Sistem Rekomendasi.....	10
2.2. <i>Content-Based Filtering</i>	10
2.3. <i>Artificial Neural Network (ANN)</i>	12
2.4. Klasifikasi.....	16
2.5. <i>Natural Language Processing (NLP)</i>	18
2.6. Pengolahan Teks (<i>Text Preprocessing</i>).....	20
2.7. TF-IDF (<i>Term Frequency-Inverse Document Frequency</i>).....	22
2.8. <i>Cosine Similarity</i>	25
2.9. Evaluasi Model.....	26
2.10. CRISP-DM (<i>Cross Industry Standard Process for Data Mining</i>).....	29
2.11. Teori Resep	31
2.12. <i>Framework Web</i>	33
BAB III METODOLOGI PENELITIAN	36
3.1. Pemahaman Masalah dan Tujuan (<i>Business Understanding</i>).....	37
3.2. Pemahaman Data (<i>Data Understanding</i>)	38
3.3. Persiapan Data (<i>Data Preparation</i>).....	40
3.4. Pemodelan (<i>Modeling</i>).....	42
3.5. Evaluasi (<i>Evaluation</i>).....	44

3.6. Penyebaran (<i>Deployment</i>).....	45
DAFTAR PUSTAKA	47

DAFTAR TABEL

Tabel 1.1 Posisi Penelitian.....	3
Tabel 3.1 Struktur dan Kategori Atribut Utama Dataset.....	39

DAFTAR GAMBAR

Gambar 2.1 Mekanisme Kerja Content-Based Filtering.....	11
Gambar 2.2 Arsitektur Dasar Artificial Neural Network (ANN).....	13
Gambar 2.3 Alur Pelatihan Artificial Neural Network (ANN).....	15
Gambar 2.4 Visualisasi Binary Classification dan Multiclass Classification.....	17
Gambar 2.5 Diagram Alur Proses Perhitungan TF-IDF	24
Gambar 2.6 Ilustrasi Sudut antara Dua Vektor pada Cosine Similarity	26
Gambar 2.7 Ilustrasi Confusion Matrix	28
Gambar 2.8 Ilustrasi Tahapan Metodologi CRISP-DM.....	30
Gambar 2.9 Ilustrasi Pola MVC pada Web Framework	34
Gambar 3.1 Flowchart Alur Penelitian	36
Gambar 3.2 Flowchart Tahapan Persiapan Data	40
Gambar 3.3 Rancangan Awal Arsitektur Artificial Neural Network (ANN).....	43

DAFTAR ISTILAH

1. ***Artificial Neural Network (ANN)***
Algoritma jaringan saraf tiruan yang merepresentasikan proses di otak manusia, digunakan untuk memodelkan klasifikasi data, mengekstraksi fitur secara otomatis, dan mengenali pola kompleks secara presisi.
2. ***Case Folding***
Tahap prapemrosesan teks yang menyeragamkan seluruh huruf menjadi satu bentuk, umumnya huruf kecil (lowercase).
3. ***Confusion Matrix***
Tabel komputasi yang membandingkan label prediksi dari model dengan label aktual (nilai sebenarnya) pada data uji untuk mengukur performa evaluasi klasifikasi.
4. ***Cosine Similarity***
Metode pengukuran tingkat kemiripan antara dua vektor teks dengan menghitung nilai kosinus sudut di antara keduanya pada ruang multidimensi; menghasilkan nilai 0 hingga 1, di mana nilai mendekati 1 berarti kedua dokumen semakin mirip.
5. ***CRISP-DM (Cross Industry Standard Process for Data Mining)***
Metodologi standar yang terdiri dari enam tahapan utama (pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan penyebaran) yang berfungsi sebagai kerangka kerja terstruktur untuk proyek berbasis data.
6. ***Dataset***
Kumpulan basis data yang digunakan dalam penelitian, seperti *Indonesian Food Recipes Dataset* yang berisi belasan ribu data resep untuk pelatihan model.
7. ***Filtering***
Proses penyaringan dalam pengolahan teks yang berfokus pada penghapusan angka serta karakter khusus (simbol).
8. ***Food Waste***
Pemborosan bahan pangan atau limbah makanan, yang sering dipicu oleh ketidakmampuan individu dalam mengelola dan mengolah sisa bahan masakan di rumah tangga.
9. ***Hidden Layer***
Lapisan tersembunyi pada arsitektur ANN yang menerima data dari *input layer* dan bertugas melakukan komputasi bobot matematika untuk mengekstraksi fitur serta mengenali pola kompleks.
10. ***Information Overload***

Kondisi kelebihan informasi, contohnya melimpahnya resep masakan di internet yang justru menyulitkan pengguna untuk menemukan resep yang spesifik secara presisi.

11. *Lemmatization*

Proses pengembalian sebuah kata ke bentuk dasarnya dengan mempertimbangkan konteks tata bahasa agar makna kata tersebut tetap benar dalam kamus.

12. *Natural Language Processing (NLP)*

Cabang dari ilmu kecerdasan buatan dan bahasa komputasi yang berfokus menjembatani interaksi antara mesin dan manusia dengan cara mengubah teks tidak terstruktur menjadi format numerik yang dapat diproses oleh komputer.

13. *Overfitting*

Suatu indikasi ketika model *machine learning* terlalu menyesuaikan diri atau menghafal data latih, sehingga gagal melakukan generalisasi untuk memprediksi data yang belum pernah dilihat sebelumnya.

14. *Sistem Rekomendasi*

Perangkat lunak atau sistem penyaringan informasi yang dirancang secara otomatis untuk memprediksi probabilitas kecocokan pengguna terhadap suatu item (seperti resep masakan) guna menyederhanakan proses pengambilan keputusan.

15. *Stemming*

Tahap memotong dan menghapus imbuhan untuk mengembalikan sekumpulan token (kata) ke bentuk dasarnya agar variasi kata yang bermakna sama dapat disatukan secara komputasi.

16. *Stopword Removal*

Proses membuang kata-kata hubung, kata takaran, atau kata umum yang sering muncul namun tidak memberikan nilai klasifikasi yang kuat (seperti "dan", "secukupnya", "siung").

17. *Term Frequency-Inverse Document Frequency (TF-IDF)*

Metode ekstraksi fitur untuk mengubah kata-kata menjadi matriks vektor numerik dengan memberikan bobot perhitungan berdasarkan seberapa sering kata tersebut muncul dalam satu dokumen versus kelangkaannya di seluruh dokumen.

18. *Text Preprocessing*

Rangkaian tahapan prapemrosesan dan pembersihan teks mentah (meliputi *case folding*, *filtering*, *tokenizing*, *stopword removal*, dan *stemming*) agar teks tersebut menjadi terstandarisasi dan siap diolah.

19. *Tokenizing (Tokenization)*

Proses pemecahan kalimat utuh menjadi potongan-potongan kata tunggal (token) berdasarkan letak spasi dan tanda baca.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pangan merupakan kebutuhan primer bagi kelangsungan hidup manusia. Dalam pemenuhan kebutuhan pangan sehari-hari, pengolahan bahan makanan menjadi hidangan yang bergizi dan bervariasi merupakan rutinitas yang penting. Namun, pada praktiknya, pengelolaan bahan makanan, terutama di kalangan mahasiswa/anak kos dan ibu rumah tangga pemula, sering kali menghadapi kendala. Kelompok ini umumnya memiliki keterbatasan waktu dan pengalaman memasak, sehingga sering kali kebingungan menentukan menu dari bahan yang dimiliki akibat kurangnya ide atau referensi untuk mengolahnya secara optimal (Faiz & Ridhwanullah, 2025). Kondisi ini menyebabkan bahan makanan tidak kunjung dimasak hingga akhirnya rusak atau membusuk, dan pada akhirnya berujung pada *food waste* (limbah makanan) (Mulyawan & Lestari, 2019).

Sekilas, persoalan kurangnya ide ini seharusnya mudah diatasi mengingat ketersediaan resep kuliner di internet saat ini sangat melimpah. Akan tetapi, melimpahnya informasi tersebut justru menimbulkan masalah baru berupa *information overload* (kelebihan informasi), sehingga proses pencarian resep berdasarkan bahan spesifik yang tersedia di dapur menjadi tidak efisien (Wong & Yoannita, 2026). Umumnya, platform penyedia resep konvensional belum memiliki fitur pencarian berlapis (*filtering*) yang memungkinkan pengguna memilah resep secara presisi berdasarkan ketersediaan bahan baku yang dimilikinya (Sholikhah & Asmunin, 2020). Pertukaran resep secara lisan pun dinilai kurang efektif karena berisiko menghilangkan informasi penting terkait takaran bahan (Wahyuni dkk., 2018). Oleh karena itu, diperlukan suatu solusi teknologi yang dapat membantu kalangan mahasiswa/anak kos dan ibu rumah tangga dalam mempermudah aktivitas memasak sehari-hari (Rahmawan dkk., 2022).

Kompleksitas dalam penentuan menu masakan ini semakin bertambah apabila dihadapkan pada karakteristik masakan khas Indonesia. Kuliner Nusantara dikenal dengan penggunaan bahan dasar dan komposisi rempah-rempah yang sangat bervariasi (Lestari & Kusri, 2012). Kurangnya pengetahuan masyarakat

dalam meracik dan mengolah bahan dasar menjadi hidangan yang sesuai sering kali membatasi variasi cita rasa yang dihasilkan (Wahyuni dkk., 2018). Selain itu, setiap jenis hidangan menuntut kombinasi bahan penyerta dan metode memasak yang spesifik agar sesuai dengan ekspektasi pengguna (Wong & Yoannita, 2026). Karakteristik inilah yang membuat proses pencocokan antara bahan yang tersedia dengan resep yang sesuai tidak dapat dilakukan secara sederhana, melainkan membutuhkan pendekatan yang mampu mengenali pola hubungan antarbahan secara akurat.

Berbagai penelitian terdahulu telah berupaya menyelesaikan permasalahan rekomendasi resep ini melalui beragam algoritma. Pada ranah pemrosesan citra, algoritma *Convolutional Neural Network* (CNN) pernah diterapkan untuk mendeteksi bahan makanan berdasarkan gambar (Saputri dkk., 2024). Pada ranah pemrosesan teks (*Natural Language Processing*), kombinasi *Content-Based Filtering* dan *K-Nearest Neighbors* (KNN) dengan pembobotan TF-IDF telah digunakan untuk menghasilkan rekomendasi resep (Febrywinata dkk., 2025). Pengembangan antarmuka pencarian resep berbasis perangkat bergerak (*mobile*) yang memanfaatkan integrasi *Application Programming Interface* (API) pihak ketiga juga telah dieksplorasi untuk mengurangi ketergantungan pada basis data lokal (Alfin dkk., 2025). Selain itu, studi komparasi antara TF-IDF dan model bahasa IndoBERT menunjukkan bahwa kemampuan mesin dalam memahami teks sangat memengaruhi relevansi resep yang direkomendasikan (Hanum dkk., 2025).

Berdasarkan tinjauan terhadap penelitian-penelitian tersebut, masih terdapat celah penelitian yang dapat disempurnakan. Pendekatan rekomendasi yang hanya mengandalkan pembobotan statistik seperti TF-IDF dengan pengukuran kemiripan sederhana memiliki keterbatasan dalam mengenali pola hubungan non-linear antarbahan pada masakan Indonesia yang kombinasinya rumit. Di sisi lain, pendekatan berbasis citra menggunakan CNN membutuhkan sumber daya komputasi dan memori yang besar. Untuk menjembatani celah tersebut, penelitian ini mengusulkan penggunaan algoritma *Artificial Neural Network* (ANN) yang bekerja pada data tekstual. Dalam penelitian ini, TF-IDF tetap digunakan sebagai metode ekstraksi fitur untuk mengubah teks bahan menjadi data numerik, sementara

ANN berperan mempelajari pola hubungan non-linear dari fitur tersebut dan mengklasifikasikan resep yang sesuai. ANN merupakan model komputasi yang terinspirasi dari cara kerja jaringan saraf pada otak manusia, di mana sistem memperoleh pengetahuan melalui proses pembelajaran dari sekumpulan data masukan (Descania, 2022). Dengan kemampuannya mempelajari pola yang kompleks tanpa memerlukan pemrosesan citra yang berat, ANN dinilai sesuai untuk mengidentifikasi hubungan antara ketersediaan bahan dan karakteristik resep Indonesia secara akurat dan efisien.

Berdasarkan pemaparan fenomena di atas, urgensi untuk mengakomodasi keragaman kuliner Nusantara, serta celah dari penelitian terdahulu, maka penelitian ini difokuskan pada pengembangan sistem yang mampu merekomendasikan resep masakan berdasarkan ketersediaan bahan secara cepat dan akurat. Oleh karena itu, penelitian ini diberi judul **"Rancang Bangun Sistem Rekomendasi Resep Masakan Indonesia Berdasarkan Ketersediaan Bahan Menggunakan Algoritma *Artificial Neural Network* (ANN)"**.

1.2 Posisi Penelitian

Untuk memperjelas posisi dan perbedaan penelitian yang akan dilakukan terhadap penelitian-penelitian sebelumnya, penelitian ini dikomparasikan dengan beberapa penelitian terdahulu yang memiliki relevansi topik. Perbandingan metodologi dan fokus pengembangan tersebut dapat dilihat secara lebih rinci pada Tabel 1.1.

Tabel 1.1 Posisi Penelitian

No	Judul	Penulis (Tahun)	Metode yang Digunakan	Perbedaan dengan Penelitian ini
1	Deteksi Bahan Makanan Untuk Rekomendasi Resep Masakan Pada Program Diet Menggunakan Algoritma Cnn	Saputri dkk. (2024)	Pendekatan citra digital menggunakan <i>Convolutional Neural Network</i> (CNN).	Penelitian ini tidak menggunakan pemrosesan citra (gambar) bahan makanan, melainkan memproses input berbasis teks menggunakan <i>Artificial Neural Network</i> (ANN), sehingga beban komputasi yang dibutuhkan jauh lebih ringan.

2	Studi Perbandingan Kinerja Tf-Idf Dan Indobert Untuk Rekomendasi Resep Berdasarkan Ketersediaan Bahan Makanan Berbasis Website	Hanum dkk. (2025)	Ekstraksi fitur teks menggunakan TF-IDF dengan <i>Cosine Similarity</i> dan model bahasa IndoBERT.	Penelitian ini difokuskan pada perancangan arsitektur jaringan syaraf tiruan (ANN) murni untuk pemrosesan teks, alih-alih menggunakan model bahasa prapelaatihan (<i>pre-trained</i>) seperti IndoBERT.
3	Savoryai: Sistem Rekomendasi Resep Masakan Berbasis Content-Based Filtering Dan Openai Api	Faiz & Ridhwanullah (2025)	<i>Content-Based Filtering</i> dan pemanfaatan OpenAI API (GPT-4o).	Penelitian ini melatih model secara mandiri melalui proses pelatihan ANN menggunakan dataset lokal, dan sama sekali tidak bergantung pada layanan <i>Application Programming Interface</i> (API) eksternal berbayar.
4	Sistem Rekomendasi Masakan Berdasarkan Ketersediaan Bahan Menggunakan Metode Content-Based Filtering dengan Algoritma K-Nearest Neighbors	Febrywinata dkk. (2025)	<i>Content-Based Filtering</i> dan algoritma klasifikasi <i>K-Nearest Neighbors</i> (KNN).	Penelitian ini menggunakan algoritma <i>Artificial Neural Network</i> (ANN) yang secara matematis memiliki kemampuan lebih andal dalam memetakan pola non-linear dari kombinasi bahan dibandingkan metode jarak tetangga (KNN) klasik.
5	Pengembangan Aplikasi Rekomendasi Resep Makanan Berdasarkan Bahan Menggunakan Api	Alfin dkk. (2025)	Pengembangan <i>mobile</i> menggunakan kerangka kerja <i>Flutter</i> dan API TheMealDB.	Penelitian ini dibangun dengan arsitektur berbasis <i>Website</i> (bukan aplikasi <i>mobile</i>), dan memusatkan basis data pelatihannya pada resep masakan khas Indonesia secara eksklusif.
6	Rancang Bangun Sistem Rekomendasi Resep Masakan Berdasarkan Bahan Baku Dengan Menggunakan	Mulyawan & Lestari (2019)	<i>Content-Based Filtering Algorithm</i> (CBFA) berbasis pemrosesan skrip PHP.	Penelitian ini mengimplementasikan algoritma pembelajaran mesin <i>Artificial Neural Network</i> (ANN) yang mampu mengenali pola data secara lebih dinamis, alih-alih sekadar menggunakan

	Algoritma Penyaringan Berdasarkan Konten			perhitungan bobot (<i>weight</i>) linier berbasis <i>query</i> pada PHP.
7	Sistem Rekomendasi Resep Makanan Dengan Metode Collaborative Filtering Dan FP- Growth Menggunakan API thymealdb.com	Sholikhah & Asmunin (2020)	<i>Collaborative Filtering</i> dan algoritma asosiasi FP-Growth menggunakan API TheMealDB.	Penelitian ini menggunakan model rekomendasi berbasis konten dari dataset mandiri (lokal) yang diolah melalui ANN, tanpa melibatkan parameter kolaborasi antar pengguna (<i>Collaborative Filtering</i>) maupun aturan asosiasi FP- Growth.
8	Sistem Rekomendasi Resep Masakan Menggunakan Kombinasi Metode ROC dan SAW	Wahyuni dkk. (2018)	Sistem Pendukung Keputusan (SPK) dengan kombinasi metode pembobotan <i>Rank Order Centroid</i> (ROC) dan <i>Simple Additive Weighting</i> (SAW).	Penelitian ini menggeser paradigma dari pembobotan multikriteria manual menjadi prediksi mandiri yang diotomatisasi oleh kecerdasan buatan melalui arsitektur <i>Artificial Neural Network</i> (ANN).
9	Aplikasi Pendeteksi Makanan Dan Rekomendasi Resep Masakan Khas Indonesia	Rahmawan dkk. (2022)	Aplikasi pendeteksi makanan berbasis <i>Computer Vision</i> (CV) dan <i>Natural Language Processing</i> (NLP).	Penelitian ini mereduksi kompleksitas sistem dengan menghilangkan fitur <i>Computer Vision</i> (pendeteksian citra visual), guna memusatkan seluruh daya komputasi secara spesifik pada pengolahan teks dengan ANN.
10	Implementasi Tf- Idf Dan Cosine Similarity Untuk Rekomendasi Resep Masakan Indonesia Berdasarkan Bahan Makanan	Wong & Yoannita (2026)	<i>Content-Based Filtering</i> dengan TF- IDF, <i>Cosine Similarity</i> , dan deteksi <i>fuzzy matching</i> (koreksi <i>typo</i>).	Penelitian ini mengeksplorasi kemampuan pemetaan pola (<i>pattern recognition</i>) pada <i>hidden layers</i> dalam arsitektur ANN, bukan sekadar bersandar pada perhitungan jarak vektor kemiripan kosinus (<i>Cosine Similarity</i>).
11	Prediksi Pertumbuhan Penduduk Di	Descania (2022)	<i>Artificial Neural Network</i> (ANN) untuk	Meskipun sama-sama menggunakan algoritma ANN, penelitian ini

	Kecamatan Baregbeg Kabupaten Ciamis Menggunakan Metode Artificial Neural Network		prediksi/peramalan (<i>forecasting</i>).	berfokus pada prediksi angka pertumbuhan penduduk berbasis data numerik, sedangkan penelitian yang akan dilakukan menggunakan ANN untuk klasifikasi dan sistem rekomendasi resep masakan berbasis pemrosesan teks.
12	Rancang Bangun Sistem Rekomendasi Resep Masakan Indonesia Berdasarkan Ketersediaan Bahan Menggunakan Algoritma <i>Artificial Neural Network</i> (ANN)	Muhamad Rifqi Salim (2026)	<i>Artificial Neural Network</i> (ANN) dan pemrosesan data tekstual berbasis <i>Website</i> .	Penelitian ini mengusulkan alternatif sistem rekomendasi yang memadukan pemrosesan teks bahan makanan dengan algoritma ANN. Fokus utamanya adalah merancang sistem berbasis <i>web</i> yang ringan (tanpa pemrosesan citra) dan mandiri (tanpa API pihak ketiga) khusus untuk resep masakan Indonesia.

1.3 Rumusan Masalah

Berdasarkan pemaparan fenomena dan celah penelitian pada latar belakang yang telah diuraikan, maka rumusan masalah pada penelitian ini difokuskan pada: Bagaimana merancang dan membangun sistem rekomendasi resep masakan khas Indonesia berbasis web menggunakan algoritma *Artificial Neural Network* (ANN) berdasarkan input ketersediaan bahan makanan?

1.4 Tujuan Penelitian

Sejalan dengan rumusan masalah yang telah ditetapkan, adapun tujuan yang ingin dicapai dari pelaksanaan penelitian ini adalah: Menghasilkan sebuah sistem rekomendasi resep masakan khas Indonesia berbasis web yang menerapkan algoritma *Artificial Neural Network* (ANN) untuk memberikan rekomendasi resep berdasarkan daftar bahan yang dimasukkan pengguna, sehingga dapat membantu kalangan mahasiswa dan ibu rumah tangga dalam menentukan menu masakan dari bahan yang tersedia.

1.5 Batasan Masalah

Agar pelaksanaan penelitian ini lebih terarah, fokus, dan tidak menyimpang dari tujuan utama yang telah ditetapkan, maka diberikan batasan-batasan masalah sebagai berikut:

1. Sistem rekomendasi yang dibangun dan diimplementasikan berbasis web (tidak mencakup pengembangan pada platform *mobile* seperti Android atau iOS).
2. Dataset yang digunakan adalah *Indonesian Food Recipes Dataset* dari Kaggle dengan jumlah ± 14.945 data resep, yang dibatasi secara eksklusif pada resep masakan khas Indonesia.
3. Atribut data yang digunakan meliputi *Title* (judul resep), *Ingredients* (bahan), *Category* (kategori/label), dan *Steps* (langkah memasak).
4. Format input yang dapat diterima dan diproses oleh sistem dibatasi hanya berupa teks (*Natural Language*) yang berisi daftar ketersediaan bahan makanan pengguna, dan tidak mencakup pemrosesan input dalam bentuk citra/gambar (*Computer Vision*) maupun suara (*Voice Recognition*).
5. Sistem dikembangkan menggunakan bahasa pemrograman Python dengan *framework* Flask.
6. Output yang dihasilkan oleh sistem berfokus pada pemberian rekomendasi judul resep beserta instruksi pengolahannya yang memiliki relevansi tertinggi dengan bahan baku yang diinputkan pengguna, serta tidak memperhitungkan informasi gizi, jumlah kalori, takaran porsi, maupun estimasi harga bahan.
7. Resep yang direkomendasikan terbatas pada resep yang tersedia di dalam dataset, sehingga sistem tidak menghasilkan kreasi resep baru di luar data yang digunakan.

1.6 Manfaat Penelitian

Manfaat yang diharapkan dari pelaksanaan penelitian ini terbagi menjadi dua aspek utama, yaitu aspek teoretis dan aspek praktis, dengan penjabaran sebagai berikut:

1.6.1 Aspek Teoretis

1. Memberikan kontribusi terhadap pengembangan keilmuan di bidang Informatika, khususnya mengenai implementasi dan evaluasi kinerja algoritma *Artificial Neural Network* (ANN) dalam ruang lingkup pemrosesan teks (*Natural Language Processing*) pada kasus sistem rekomendasi.
2. Menjadi rujukan dan landasan literatur bagi penelitian selanjutnya yang berfokus pada pengembangan model kecerdasan buatan untuk memetakan pola kombinasi bahan makanan, khususnya pada ragam kuliner khas Indonesia.

1.6.2 Aspek Praktis

1. Memberikan solusi teknologi berbasis web yang mudah diakses dan mudah digunakan, khususnya bagi mahasiswa/anak kos dan ibu rumah tangga, guna mempermudah pencarian ide atau referensi resep masakan yang sesuai dengan ketersediaan bahan baku di dapur.
2. Membantu menekan tingkat pembuangan limbah makanan (*food waste*) di skala rumah tangga dengan cara mengoptimalkan pengolahan bahan masakan agar tidak menumpuk, rusak, atau membusuk.

1.7 Sistematika Penulisan

Untuk memberikan gambaran yang komprehensif dan terstruktur mengenai alur penyusunan Proposal Penelitian ini, maka laporan dibagi menjadi tiga bab dengan sistematika penulisan sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan landasan awal penelitian yang mencakup latar belakang masalah mengenai sistem rekomendasi resep, posisi penelitian, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan laporan.

BAB II LANDASAN TEORI

Bab ini berisi tinjauan pustaka dari penelitian-penelitian terdahulu yang relevan serta pemaparan teori dasar yang mendukung jalannya penelitian. Teori yang dibahas secara spesifik meliputi konsep sistem rekomendasi, algoritma *Artificial*

Neural Network (ANN), pemrosesan teks (*Natural Language Processing*), serta teknologi pengembangan sistem rekomendasi resep berbasis *web*.

BAB III METODOLOGI PENELITIAN

Bab ini memaparkan tahapan penelitian yang dilakukan secara sistematis, mulai dari metode pengumpulan data (*dataset*) resep masakan khas Indonesia, perancangan arsitektur model ANN, perancangan antarmuka dan basis data sistem, hingga perumusan skenario pengujian yang akan dieksekusi.

BAB II

LANDASAN TEORI

2.1. Sistem Rekomendasi

Perkembangan teknologi informasi membuat jumlah data digital meningkat sangat pesat, termasuk pada bidang kuliner. Kondisi ini menimbulkan *information overload*, yaitu keadaan ketika pengguna kesulitan menemukan informasi yang relevan dari banyaknya data yang tersedia. Untuk mengatasi permasalahan tersebut dikembangkan sistem rekomendasi (*recommendation system*), yaitu teknologi yang membantu pengguna menemukan item yang relevan dari sejumlah besar data secara otomatis (Wong & Yoannita, 2026).

Pada dasarnya, sistem rekomendasi berfungsi memberikan saran kepada pengguna mengenai item yang sebaiknya dipilih atau digunakan (Sholikhah & Asmunin, 2020). Dengan demikian, sistem ini membantu pengguna mengambil keputusan secara lebih cepat di tengah banyaknya pilihan, sekaligus memungkinkan pengguna menemukan item yang sebelumnya belum diketahui.

Secara umum, sistem rekomendasi bekerja dengan menganalisis karakteristik item dan preferensi pengguna untuk membentuk sebuah model penilaian. Berdasarkan model tersebut, sistem menghitung bobot kecocokan pada setiap item, kemudian menyusun keluaran berupa daftar rekomendasi yang diurutkan dari nilai relevansi tertinggi ke terendah (Wahyuni dkk., 2018).


Dalam praktiknya, terdapat beberapa metode pemfilteran yang dapat digunakan, disesuaikan dengan ketersediaan data dan atributnya. Salah satu pendekatan yang umum adalah mencocokkan fitur yang melekat pada item dengan preferensi yang dimasukkan oleh pengguna (Faiz & Ridhwanullah, 2025). Ketika rekomendasi perlu dihasilkan hanya berdasarkan kesamaan fitur dari item itu sendiri tanpa bergantung pada data interaksi pengguna lain, metode yang paling sesuai untuk diterapkan adalah *content-based filtering*.

2.2. Content-Based Filtering

Content-based filtering merupakan salah satu pendekatan utama dalam sistem rekomendasi yang berfokus pada analisis fitur atau atribut dari sebuah item. Metode ini merekomendasikan item baru berdasarkan kesamaan fiturnya dengan item yang

pernah disukai pengguna sebelumnya, atau berdasarkan kriteria yang dimasukkan pengguna secara langsung (Mulyawan & Lestari, 2019). Menurut Pernanda dkk., 2023, algoritma berbasis konten bekerja dengan menganalisis spesifikasi atau fitur dari setiap item yang ada di dalam basis data. Berbeda dengan *collaborative filtering* yang bergantung pada riwayat interaksi atau penilaian dari banyak pengguna, *content-based filtering* tidak memerlukan data pengguna lain karena bertumpu pada kecocokan antara preferensi pengguna dan fitur item itu sendiri (Mulyawan & Lestari, 2019).

Secara teknis, mekanisme kerja *content-based filtering* terdiri atas beberapa tahapan. Tahap pertama adalah ekstraksi fitur (*feature extraction*), yaitu mengubah atribut atau metadata teks dari suatu item menjadi representasi vektor numerik. Selanjutnya, sistem membentuk profil pengguna yang merangkum preferensi atau masukan pengguna. Profil tersebut kemudian dibandingkan dengan profil item menggunakan perhitungan kemiripan, seperti *cosine similarity*, untuk menghasilkan nilai kemiripan (*similarity score*). Item dengan *similarity score* tertinggi akhirnya dipilih dan ditampilkan sebagai hasil rekomendasi (Febrywinata dkk., 2025).



Gambar 2.1 Mekanisme Kerja *Content-Based Filtering*

Sumber Gambar: (Maulid, 2023)

Berdasarkan Gambar 2.1, alur pemfilteran berbasis konten dapat diamati secara visual. Ketika pengguna menunjukkan ketertarikan pada suatu item, sistem

mengekstraksi atribut atau kategori yang menyusun item tersebut. Fitur yang telah diekstraksi kemudian dijadikan representasi preferensi pengguna. Berdasarkan representasi itu, sistem menelusuri basis data untuk mencari item lain yang memiliki kesamaan fitur, lalu menyajikan item yang paling relevan kepada pengguna (Mulyawan & Lestari, 2019).

Keunggulan utama *content-based filtering* terletak pada kemampuannya memberikan rekomendasi yang personal dan tidak bergantung pada data pengguna lain (Febrywinata dkk., 2025). Karena rekomendasi dihasilkan murni dari fitur item, metode ini tetap dapat bekerja meskipun data dari banyak pengguna tidak tersedia, selama setiap item memiliki fitur yang terdefinisi dengan baik (Mulyawan & Lestari, 2019). Karakteristik ini membuat *content-based filtering* cocok diterapkan pada basis data yang dinamis atau ketika data dari banyak pengguna sulit diperoleh.

Meskipun demikian, *content-based filtering* juga memiliki keterbatasan. Karena rekomendasi hanya didasarkan pada kesamaan fitur, hasil yang diberikan cenderung kurang beragam dan terbatas pada item yang mirip dengan preferensi awal pengguna. Selain itu, pencocokan fitur secara tradisional umumnya hanya mengandalkan kemunculan kata tanpa memahami konteksnya, sehingga kurang mampu menangkap hubungan makna (semantik) yang lebih dalam antar-fitur (Hanum dkk., 2025).


Untuk mengatasi keterbatasan tersebut dan meningkatkan kualitas rekomendasi, sistem rekomendasi modern mulai mengintegrasikan metode *machine learning* yang lebih mampu memahami pola hubungan yang kompleks serta makna semantik dari data (Hanum dkk., 2025). Di antara berbagai metode kecerdasan buatan, salah satu yang banyak digunakan untuk menangani pemetaan non-linear dan ekstraksi fitur yang lebih mendalam adalah *Artificial Neural Network* (ANN).

2.3. *Artificial Neural Network* (ANN)

Artificial Neural Network (ANN) atau Jaringan Saraf Tiruan merupakan model komputasi dalam kecerdasan buatan yang memproses informasi melalui jaringan unit-unit pemroses yang saling terhubung. Secara konseptual, ANN

terinspirasi oleh mekanisme kerja jaringan saraf biologis pada otak manusia, di mana sel-sel saraf saling terhubung untuk menerima, mengolah, dan meneruskan sinyal. Prinsip dasar ANN adalah menggunakan unit pemrosesan buatan yang saling berinteraksi untuk mempelajari pola-pola dari sekumpulan data secara berulang (Descania, 2022). Berbeda dengan sistem berbasis aturan statis yang kaku, ANN memiliki kemampuan untuk menyesuaikan parameter internalnya secara mandiri selama proses pembelajaran agar tingkat ketepatan prediksinya semakin meningkat seiring bertambahnya data yang dipelajari.

Arsitektur dasar ANN umumnya terorganisir ke dalam tiga jenis lapisan utama, yaitu *input layer* (lapisan masukan), *hidden layer* (lapisan tersembunyi), dan *output layer* (lapisan keluaran). *Input layer* berfungsi menerima data dari luar sistem, *hidden layer* bertugas melakukan transformasi matematis serta pemetaan fitur-fitur penting, sedangkan *output layer* memberikan hasil akhir dari proses pengolahan tersebut. Lapisan tersembunyi sendiri dapat terdiri atas satu atau beberapa lapisan, bergantung pada kompleksitas masalah yang ditangani. Di dalam setiap lapisan terdapat unit komputasi terkecil yang disebut neuron. Setiap neuron saling terhubung melalui bobot (*weights*) yang menentukan kekuatan sinyal antar saraf, serta bias sebagai penyeimbang nilai. Selain itu, terdapat fungsi aktivasi (*activation function*) yang berperan menentukan apakah suatu informasi diteruskan ke saraf berikutnya atau tidak (Purwitasari & Soleh, 2022).




Gambar 2.2 Arsitektur Dasar *Artificial Neural Network* (ANN)

Sumber Gambar: (Bre dkk., 2018)

Berdasarkan Gambar 2.2, dapat dilihat struktur sebuah jaringan saraf tiruan yang mengalirkan data dari kiri ke kanan. Data masukan diterima oleh lapisan paling kiri, kemudian dialirkan menuju satu atau beberapa lapisan tersembunyi yang pada Gambar 2.2 ditunjukkan sebagai h_1 , h_2 , hingga h_n . Di dalam lapisan-lapisan tersembunyi inilah terjadi proses pengolahan data yang paling kompleks, di mana setiap koneksi antar saraf memiliki bobot tertentu yang akan disesuaikan selama masa pelatihan. Setelah melalui berbagai perhitungan di lapisan tersembunyi, sistem meneruskan sinyal tersebut ke lapisan paling kanan untuk menghasilkan sebuah nilai keluaran. Struktur berlapis ini memungkinkan ANN menangkap hubungan-hubungan rumit di dalam data yang tidak dapat dilihat secara kasat mata (Descania, 2022).

Proses agar ANN dapat menghasilkan keluaran yang akurat dilakukan melalui siklus pelatihan yang bersifat iteratif. Pelatihan ini melibatkan dua fase utama, yaitu *forward propagation* (perambatan maju) dan *backpropagation* (perambatan balik). Pada fase maju, data mengalir dari lapisan masukan hingga menghasilkan nilai prediksi atau hasil keluaran model. Hasil ini kemudian dibandingkan dengan nilai yang seharusnya untuk mengetahui seberapa besar tingkat kesalahan (*loss/error*) yang dihasilkan model. Jika tingkat kesalahan masih tinggi, sistem akan menjalankan fase perambatan balik untuk memperbaiki nilai bobot dan bias di setiap saraf. Siklus ini terus diulang pada setiap *epoch* hingga model mampu menghasilkan nilai prediksi dengan tingkat kesalahan yang paling minimal (Purwitasari & Soleh, 2022).



Gambar 2.3 Alur Pelatihan *Artificial Neural Network* (ANN)

Sumber Gambar:(Tuntas & Dikici, 2016)

Gambar 2.3 mengilustrasikan urutan langkah yang ditempuh sistem dalam melatih jaringan saraf tiruan. Proses diawali dengan menentukan parameter masukan dan keluaran, membagi data menjadi data latih, validasi, dan uji, serta menetapkan algoritma pembelajaran. Selanjutnya, nilai bobot dan bias diinisialisasi secara acak sebagai titik awal pelatihan. Sistem kemudian mengolah data untuk menghasilkan prediksi dan membandingkannya dengan nilai sebenarnya guna mengukur tingkat kesalahan (*error*). Jika target kesalahan belum tercapai, sistem akan menambah iterasi dan menyesuaikan parameter pelatihan seperti jumlah lapisan tersembunyi, jumlah neuron, serta nilai bobot dan bias lalu mengulang proses validasi. Siklus ini berlangsung hingga target kesalahan tercapai, sehingga pada akhirnya diperoleh arsitektur jaringan terbaik yang siap digunakan untuk melakukan prediksi (Purwitasari & Soleh, 2022).

Keunggulan utama ANN terletak pada kemampuannya dalam memodelkan hubungan data yang tidak beraturan (*non-linear*) serta mengekstraksi fitur secara otomatis tanpa perlu ditentukan secara manual oleh manusia. Namun demikian, ANN memiliki tantangan tersendiri, seperti kebutuhan daya komputasi yang besar serta sifatnya yang cenderung dianggap sebagai kotak hitam (*black box*), di mana sulit bagi manusia untuk memahami secara persis bagaimana sistem mengambil keputusan di dalam lapisan tersembunyinya. Meskipun begitu, ANN tetap menjadi landasan teoretis yang sangat penting dalam pengembangan sistem cerdas karena efektivitasnya yang tinggi dalam menangani tugas pengenalan pola dan klasifikasi data (Descania, 2022; Purwitasari & Soleh, 2022). Pemahaman terhadap mekanisme kerja ANN ini menjadi dasar bagi pembahasan mengenai bagaimana sistem akan mengklasifikasikan kueri resep pengguna pada bab-bab selanjutnya.


2.4. Klasifikasi

Klasifikasi merupakan salah satu tugas mendasar dalam *machine learning* yang bertujuan untuk mengategorikan data ke dalam kelas-kelas yang telah ditentukan sebelumnya. Secara konsep, proses ini berbeda dengan regresi; jika regresi dirancang untuk memprediksi nilai berupa angka yang berkelanjutan (*continuous*), klasifikasi berupaya memetakan variabel masukan ke dalam kategori target yang saling terpisah (Ananda dkk., 2024). Dalam kecerdasan buatan, tugas klasifikasi ini dapat diselesaikan dengan tingkat akurasi tinggi menggunakan arsitektur *Artificial Neural Network* (ANN) seperti yang telah dibahas sebelumnya. Jaringan saraf tiruan memiliki kemampuan untuk mempelajari pola non-linear yang rumit, sehingga mampu membentuk batas keputusan (*decision boundaries*) yang kuat untuk memisahkan berbagai kelas data secara optimal.

Secara operasional, klasifikasi umumnya beroperasi di bawah kerangka kerja *supervised learning*. Mekanisme pembelajaran ini sangat bergantung pada ketersediaan data latih historis yang telah diberi label atau penanda kelas yang benar. Dalam ekosistem ini, setiap titik data diwakili oleh sekumpulan fitur (*features*), yaitu karakteristik atau atribut dari data tersebut, yang kemudian dianalisis oleh algoritma untuk memprediksi variabel target secara akurat (Descania, 2022). Keseluruhan proses ini dilakukan melalui dua tahapan utama,

yakni fase pelatihan (*training phase*) dan fase pengujian (*testing/prediction phase*). Pada fase pelatihan, algoritma secara berulang menganalisis fitur dan mencocokkannya dengan label untuk membangun sebuah model matematis. Setelah model tersebut dilatih, fase pengujian dilakukan menggunakan data baru yang belum pernah dilihat sebelumnya untuk menguji sejauh mana model mampu memprediksi label dengan tepat.

Berdasarkan jumlah kategori yang menjadi target, klasifikasi dibedakan menjadi dua jenis utama, yaitu *binary classification* dan *multiclass classification*. Model *binary classification* digunakan ketika algoritma harus membedakan antara dua kelas saja, sedangkan *multiclass classification* melibatkan pengelompokan ke dalam tiga kelas atau lebih secara bersamaan. Untuk menyelesaikan berbagai tingkat kerumitan pemisahan data ini, terdapat beragam algoritma yang lazim digunakan, contohnya *Logistic Regression* yang berbasis peluang statistik, *Decision Tree* yang membagi data melalui aturan bersyarat, serta *Support Vector Machine* yang berupaya mencari batas pemisah terbaik antar kelas. Selain metode konvensional tersebut, *Neural Network* menjadi sangat dominan untuk tugas klasifikasi, terutama ketika sistem berhadapan dengan data berdimensi banyak dan menuntut pengenalan fitur tingkat lanjut (Ananda dkk., 2024).



Gambar 2.4 Visualisasi *Binary Classification* dan *Multiclass Classification*

Sumber Gambar: (Firmansyah, 2025)

Berdasarkan Gambar 2.4, perbedaan konseptual antara kedua jenis klasifikasi tersebut dapat diamati secara visual melalui pembentukan batas keputusan (*decision*

boundary). Pada ilustrasi *binary classification* di sebelah kiri, algoritma hanya perlu menarik satu garis pemisah untuk mengelompokkan titik-titik data ke dalam dua kelas yang saling berseberangan (diwakili oleh tanda silang merah dan segitiga ungu). Sebaliknya, pada ilustrasi *multiclass classification* di sebelah kanan, tingkat kerumitan komputasinya meningkat karena sistem harus membangun beberapa garis batas pemisah sekaligus untuk mengkategorikan tiga atau lebih kelompok data yang berbeda (tanda silang merah, segitiga ungu, lingkaran biru, dan kotak hijau). Kemampuan membagi ruang data dengan garis-garis pemisah inilah yang menjadi inti keberhasilan model dalam mengenali pola data (Ananda dkk., 2024).

Kemampuan adaptasi dan generalisasi yang tinggi membuat model klasifikasi dapat diterapkan secara luas di berbagai bidang, misalnya untuk membantu diagnosis medis berdasarkan rekam medis pasien atau untuk pengenalan objek dan wajah dalam citra. Cakupan penerapan yang tidak terbatas pada data angka ini menunjukkan bahwa klasifikasi merupakan metode yang fleksibel untuk mengubah beragam jenis masukan menjadi keputusan kategori.

Selain memproses angka dan gambar, prinsip dasar klasifikasi juga sangat penting dalam menganalisis informasi berbentuk teks yang pada dasarnya tidak terstruktur. Algoritma klasifikasi, termasuk model berbasis jaringan saraf tiruan, mampu melakukan *text classification*, seperti menentukan topik utama dari sebuah dokumen atau menilai sentimen dari suatu opini tertulis (Purwitasari & Soleh, 2022). Meskipun demikian, proses mengubah susunan kata dari bahasa alami menjadi representasi fitur matematis agar dapat diproses oleh model sangatlah rumit dan membutuhkan teknik komputasi bahasa yang khusus. Tantangan dalam menerjemahkan teks menjadi angka dan mengekstraksi makna dari bahasa manusia inilah yang menjadi dasar bagi pengembangan sistem pemrosesan bahasa, yang akan dibahas lebih mendalam pada subbab berikutnya mengenai *Natural Language Processing*.

2.5. Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan cabang dari kecerdasan buatan dan ilmu bahasa komputasi yang berfokus pada interaksi antara komputer dan bahasa manusia. Tujuan utama NLP adalah menjembatani komunikasi antara

manusia dan mesin, yaitu dengan mengubah teks yang tidak terstruktur menjadi format data yang dapat diolah secara matematis (Purwitasari & Soleh, 2022). Dalam sistem cerdas seperti *Artificial Neural Network* (ANN), NLP sangat dibutuhkan karena mesin pada dasarnya tidak bisa memahami huruf atau teks secara langsung. Oleh karena itu, kata-kata tersebut harus diubah menjadi angka atau representasi numerik agar mesin dapat melakukan perhitungan untuk tugas klasifikasi maupun prediksi.

Secara umum, pengolahan bahasa alami menghadapi sejumlah tantangan. Salah satu tantangan utamanya adalah tingginya ambiguitas atau makna ganda dalam bahasa manusia. Sebagai contoh, satu kata bisa memiliki arti yang berbeda tergantung pada konteks kalimatnya, atau sebaliknya, beberapa kata yang berbeda dapat merujuk pada maksud yang sama (sinonim). Selain itu, sistem komputasi juga umumnya harus berhadapan dengan variasi gaya bahasa, singkatan, serta susunan kalimat yang tidak beraturan pada teks nonformal. Untuk mengatasi hambatan tersebut, NLP umumnya menggunakan serangkaian tahapan analisis agar komputer tidak hanya sekadar membaca susunan kata, tetapi juga memahami makna di baliknya.

Secara umum, proses kerja NLP dalam sistem *machine learning* diimplementasikan melalui sebuah *pipeline* atau tahapan berurutan. Tahapan-tahapan tersebut dapat diuraikan sebagai berikut:

1. **Pengumpulan Data (*Text Acquisition*):** Tahap awal di mana sekumpulan data teks mentah dikumpulkan dari berbagai sumber untuk dijadikan korpus atau bahan pembelajaran mesin.
2. **Prapemrosesan (*Preprocessing*):** Tahap pembersihan dan perapian teks mentah agar lebih terstandarisasi. Proses ini meliputi pemecahan kalimat menjadi potongan kata tunggal (*tokenization*), penghapusan kata hubung yang tidak bermakna (*stopword removal*), serta penyeragaman bentuk huruf dan kata.
3. **Ekstraksi Fitur (*Feature Extraction*):** Tahap pengubahan kata-kata yang sudah bersih dan seragam menjadi susunan matriks angka. Pendekatan yang sering digunakan antara lain pembobotan frekuensi kata atau *word*

embedding, yaitu metode yang mengubah kata menjadi vektor nilai agar mesin dapat menghitung kemiripan maknanya secara matematis (Hanum dkk., 2025).

4. **Pembangunan Model (*Model Building*):** Tahap akhir di mana hasil ekstraksi fitur numerik tersebut dimasukkan ke dalam algoritma kecerdasan buatan untuk dilatih agar mampu mengenali pola dan memberikan keluaran prediksi yang tepat.

Untuk mendukung tahapan tersebut, NLP secara umum juga dapat dibantu oleh teknik linguistik yang lebih spesifik, misalnya *Part-of-Speech* (POS) *tagging* yang bertugas mengenali jenis kata (apakah sebuah kata merupakan kata benda atau kata kerja berdasarkan posisinya), serta *Named Entity Recognition* (NER) untuk mengidentifikasi objek spesifik seperti nama orang atau lokasi di dalam teks.

Khusus untuk pengolahan teks berbahasa Indonesia, tantangan komputasinya menjadi lebih kompleks karena struktur morfologinya yang kaya akan imbuhan serta banyaknya ragam bahasa tidak baku dan kata serapan asing (Purwitasari & Soleh, 2022). Kerumitan ini menunjukkan bahwa teks mentah belum dapat langsung diolah oleh model machine learning, sehingga diperlukan serangkaian tahapan pembersihan data yang terstruktur. Tahapan tersebut akan dibahas secara mendalam pada subbab berikutnya mengenai pengolahan teks (*text preprocessing*).

2.6. Pengolahan Teks (*Text Preprocessing*)

Pengolahan teks atau *text preprocessing* merupakan tahapan krusial dalam alur kerja *Natural Language Processing* (NLP). Secara umum, *text preprocessing* adalah serangkaian teknik komputasi untuk membersihkan, merapikan, dan mengubah teks mentah yang tidak beraturan menjadi data yang terstandarisasi. Algoritma *machine learning* pada dasarnya tidak memiliki kemampuan untuk menoleransi variasi cara penulisan atau kesalahan ketik yang sering dilakukan manusia. Oleh karena itu, kualitas prediksi dari sebuah model sangat bergantung pada seberapa bersih data masukan yang diberikan (Purwitasari & Soleh, 2022). Tujuan utama dari tahap ini adalah membuang gangguan (*noise*) pada teks dan menyederhanakan jumlah kosakata, sehingga komputer bisa lebih fokus mencari pola kata yang benar-benar penting.

Secara operasional, *text preprocessing* dilakukan secara berurutan melalui beberapa tahapan utama, yaitu:

1. **Pembersihan Karakter (*Filtering*):** Tahapan ini dilakukan untuk menghapus karakter-karakter yang dianggap sebagai gangguan (*noise*) dalam proses pengolahan teks. Karakter tersebut meliputi angka (0-9), tanda baca (seperti titik, koma, tanda kurung), serta simbol-simbol khusus lainnya. Pada kasus data resep masakan, tahap ini sangat vital untuk memisahkan nama bahan dari atribut ukuran atau kuantitas (misalnya menghapus angka "500" dari teks "500 gram gula") sehingga model hanya mempelajari entitas bahannya saja.
2. **Penyeragaman Huruf (*Case Folding*):** Tahap untuk menormalkan karakter dengan cara mengubah seluruh huruf dalam dokumen menjadi bentuk yang seragam, biasanya menjadi huruf kecil (*lowercase*). Tahap ini sangat penting agar komputer menganggap kata yang sama meskipun satu menggunakan huruf kapital dan lainnya huruf kecil sebagai satu kesatuan makna yang identik.
3. **Pemotongan Kata (*Tokenization*):** Tahap memecah kalimat yang panjang menjadi potongan-potongan kata tunggal (disebut sebagai *token*) berdasarkan letak spasi maupun tanda baca. Kumpulan token inilah yang nantinya akan dihitung dan dianalisis oleh komputer.
4. **Penghapusan Kata Hubung (*Stopword Removal*):** Tahap membuang kata-kata yang sangat sering muncul tetapi tidak memberikan arti penting pada kalimat, seperti konjungsi atau preposisi (contoh: "dan", "yang", "di", "itu"). Penghapusan kata-kata ini akan sangat meringankan beban perhitungan komputer karena mengurangi jumlah kata yang tidak perlu diproses (Hanum dkk., 2025).
5. **Pengembalian Kata Dasar (*Stemming dan Lemmatization*):** Tahap memotong imbuhan untuk mengembalikan suatu token ke bentuk dasarnya. Terdapat dua pendekatan utama: *stemming* dan *lemmatization*. *Stemming* bekerja dengan sangat cepat karena hanya memotong awalan atau akhiran secara langsung berdasarkan aturan baku tanpa memedulikan makna

akhirnya. Sebaliknya, *lemmatization* bekerja lebih teliti dengan melihat konteks tata bahasa untuk memastikan kata yang dipotong tetap memiliki makna yang benar dalam kamus. Biasanya, *stemming* dipilih untuk mempercepat pemrosesan data berskala besar, sementara *lemmatization* digunakan jika ketepatan makna sangat diutamakan.

Khusus untuk korpus berbahasa Indonesia, proses pemotongan imbuhan (*stemming*) dan perapian teks menghadapi tantangan yang jauh lebih rumit dibandingkan bahasa Inggris. Bahasa Indonesia sangat kaya akan penggunaan imbuhan, baik berupa awalan (prefiks), akhiran (sufiks), sisipan (infiks), maupun gabungan di antaranya (konfiks). Penambahan imbuhan ini dapat mengubah satu kata dasar menjadi banyak variasi bentuk dengan makna yang sangat berbeda (Purwitasari & Soleh, 2022). Selain itu, banyaknya singkatan tidak baku dalam bahasa gaul, kata majemuk, serta kata serapan asing yang belum baku menuntut penggunaan aturan algoritma khusus (misalnya algoritma Nazief & Adriani) agar pemotongan kata bahasa Indonesia menjadi lebih akurat.

Keseluruhan tahapan *text preprocessing* ini mutlak diperlukan untuk menjamin kualitas fitur sebelum data tersebut dipelajari oleh model *machine learning*. Hasil akhir dari tahap ini adalah kumpulan kata (token) yang lebih bersih, padat, dan mewakili inti informasi dari teks aslinya. Meskipun demikian, model klasifikasi seperti jaringan saraf tiruan tetap tidak dapat menerima teks ini secara langsung sebagai masukannya. Kumpulan token yang sudah bersih tersebut harus dihitung, diberi bobot, dan diubah menjadi format angka matematis. Proses pengubahan teks menjadi angka inilah yang akan dibahas lebih mendalam pada subbab berikutnya mengenai *Term Frequency-Inverse Document Frequency* (TF-IDF).

2.7. TF-IDF (*Term Frequency-Inverse Document Frequency*)

Setelah melalui tahap pengolahan teks (*text preprocessing*), potongan-potongan kata atau token yang dihasilkan belum dapat diproses secara langsung oleh algoritma *machine learning*. Model klasifikasi seperti jaringan saraf tiruan membutuhkan data dalam bentuk angka agar perhitungan matematis dapat dilakukan. Oleh karena itu, diperlukan sebuah tahap ekstraksi fitur (*feature*

extraction) untuk mengubah kata-kata tersebut menjadi susunan nilai numerik. Salah satu metode pembobotan kata yang paling umum dan fundamental digunakan dalam pengolahan bahasa alami adalah *Term Frequency-Inverse Document Frequency* atau TF-IDF (Hanum dkk., 2025). Secara konsep, TF-IDF berfungsi untuk memberikan bobot atau nilai pada setiap kata berdasarkan tingkat kepentingannya di dalam suatu dokumen, jika dibandingkan dengan seluruh dokumen yang ada.


Metode pembobotan TF-IDF terdiri dari dua komponen perhitungan utama. Komponen pertama adalah *Term Frequency* (TF), yaitu nilai yang mengukur seberapa sering sebuah kata muncul di dalam satu dokumen tunggal. Logikanya, semakin sering sebuah kata muncul pada dokumen tertentu, maka semakin besar nilai TF kata tersebut pada dokumen itu. Namun, perhitungan TF saja tidak cukup karena kata-kata umum yang sering muncul akan mendapatkan nilai tinggi meski tidak memiliki makna penting. Oleh sebab itu, diperlukan komponen kedua yaitu *Inverse Document Frequency* (IDF). IDF berfungsi mengukur tingkat kelangkaan sebuah kata pada seluruh kumpulan dokumen (*corpus*). Kata unik yang hanya muncul di sedikit dokumen akan memiliki nilai IDF yang tinggi, sedangkan kata yang muncul di hampir semua dokumen akan diberi nilai rendah karena dianggap tidak memiliki ciri khas yang kuat.

Secara matematis, tahap perhitungan pembobotan TF-IDF dapat diuraikan melalui beberapa persamaan berikut:

$$TF(t, d) = \frac{\text{Jumlah kemunculan kata } t \text{ dalam dokumen } d}{\text{Jumlah total kata dalam dokumen } d} \text{ Rumus 1}$$

$$IDF(t) = \log \frac{\text{Total jumlah dokumen dalam korpus } (D)}{\text{Jumlah dokumen yang mengandung kata } t} \text{ Rumus 2}$$

$$TF - IDF(t, d) = TF(t, d) \times IDF(t) \text{ Rumus 3}$$



Gambar 2.5 Diagram Alur Proses Perhitungan TF-IDF

Sumber Gambar: (Rahmadden dkk., 2022)

Gambar 2.5 menunjukkan diagram alur lengkap proses perhitungan TF-IDF yang dimulai dari hasil *stemming*, dilanjutkan dengan penghitungan *Term Frequency* (TF), *Document Frequency* (DF), *Inverse Document Frequency* (IDF), hingga diperoleh nilai akhir TF-IDF yang disimpan sebagai hasil perhitungan. Diagram ini memberikan gambaran visual yang jelas mengenai urutan langkah komputasi yang harus dilakukan sebelum data teks dapat digunakan sebagai *input* model *machine learning*.

Berdasarkan perhitungan pada rumus-rumus di atas, hasil akhir dari metode ekstraksi fitur ini akan membentuk sebuah matriks *term-document* berdimensi tinggi. Di dalam matriks tersebut, setiap dokumen diwakili oleh sebuah baris (vektor), sedangkan kolomnya berisi kata-kata unik dari seluruh kumpulan data. Perpotongan antara baris dan kolom tersebut diisi oleh nilai bobot angka TF-IDF. Keunggulan utama dari pendekatan ini terletak pada kesederhanaan logikanya dan efisiensi komputasinya, sehingga andal untuk digunakan pada berbagai tugas klasifikasi teks skala besar (Febrywinata dkk., 2025).

Matriks angka yang dihasilkan dari proses TF-IDF inilah yang kemudian berperan sebagai jembatan utama antara bahasa alami manusia dengan proses komputasi. Selain dapat digunakan sebagai data masukan (*input*) bagi algoritma kecerdasan buatan, representasi vektor TF-IDF ini juga memungkinkan dilakukannya pengukuran tingkat kemiripan antar dokumen. Salah satu metode yang paling umum digunakan untuk mengukur kemiripan antar vektor TF-IDF tersebut adalah *Cosine Similarity*, yang akan dibahas secara mendalam pada subbab berikutnya.

2.8. *Cosine Similarity*

Cosine Similarity merupakan salah satu metode yang paling umum digunakan untuk mengukur tingkat kemiripan antara dua buah vektor teks. Metode ini bekerja dengan pendekatan geometri, yaitu menghitung nilai kosinus dari sudut yang terbentuk di antara dua vektor pada ruang multidimensi (Febrywinata dkk., 2025). Salah satu keunggulan utamanya adalah hasil perhitungan tidak terpengaruh oleh panjang dokumen, sehingga nilai kemiripan tetap stabil meskipun dua dokumen memiliki jumlah kata yang berbeda (Wong & Yoannita, 2026).

Dalam konteks sistem rekomendasi berbasis teks, *cosine similarity* berperan sebagai tahap lanjutan setelah proses pembobotan TF-IDF. Setiap dokumen dalam penelitian ini berupa daftar bahan pada resep telah direpresentasikan sebagai vektor numerik melalui TF-IDF. *Cosine similarity* kemudian digunakan untuk membandingkan vektor masukan bahan dari pengguna dengan vektor setiap resep di dalam *dataset*, sehingga sistem dapat menentukan resep mana yang paling mendekati ketersediaan bahan pengguna (Wong & Yoannita, 2026).


Secara matematis, nilai *cosine similarity* antara dua vektor A dan B dihitung menggunakan persamaan berikut:

$$\text{Cosine Similarity}(A,B) = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}} \quad \text{Rumus 4}$$

Keterangan:

A dan B = vektor representasi dari dua dokumen yang dibandingkan;

A_i dan B_i = nilai bobot kata ke- i pada masing-masing vektor dokumen.



Gambar 2.6 Ilustrasi Sudut antara Dua Vektor pada *Cosine Similarity*

Sumber Gambar: (Shivanandhan, 2025)

Gambar 2.6 mengilustrasikan konsep dasar *cosine similarity* secara geometris, yaitu dua buah vektor (A dan B) yang membentuk sudut θ pada sebuah ruang. Semakin kecil sudut θ di antara kedua vektor, semakin besar nilai kosinusnya, yang berarti kedua dokumen semakin mirip. Secara geometris nilai kemiripan ini setara dengan perbandingan *dot product* kedua vektor terhadap perkalian besarnya (*magnitude*), sebagaimana telah dirumuskan pada Rumus 4.

Nilai yang dihasilkan oleh *cosine similarity* berada pada rentang 0 hingga 1. Nilai yang mendekati 1 menunjukkan bahwa kedua vektor memiliki tingkat kemiripan yang sangat tinggi, sedangkan nilai yang mendekati 0 menunjukkan bahwa keduanya hampir tidak memiliki kesamaan (Febrywinata dkk., 2025). Berdasarkan nilai inilah resep-resep diurutkan, sehingga resep dengan skor kemiripan tertinggi ditempatkan sebagai rekomendasi teratas bagi pengguna. Setelah sistem mampu menghasilkan rekomendasi, langkah selanjutnya adalah mengukur tingkat keberhasilan dan ketepatannya, yang akan dibahas pada subbab berikutnya mengenai evaluasi model.

2.9. Evaluasi Model

Tahapan komputasi dalam *Natural Language Processing* (NLP) maupun *machine learning* tidak berakhir setelah model selesai dilatih menggunakan representasi numerik seperti TF-IDF. Model klasifikasi yang telah mempelajari pola dari data pelatihan belum dapat langsung dianggap andal untuk digunakan,

karena performanya harus dibuktikan melalui proses evaluasi. Evaluasi model merupakan proses sistematis untuk mengukur kinerja prediksi serta menilai kemampuan model dalam melakukan generalisasi terhadap data yang belum pernah dilihat sebelumnya (Tarigan dkk., 2023). Melalui evaluasi, peneliti dapat mengidentifikasi indikasi *overfitting* (model terlalu menyesuaikan data latih) maupun *underfitting* (model gagal menangkap pola data).

Untuk memastikan evaluasi bersifat objektif, penelitian ini menggunakan konsep pemisahan data (*train-test split*), yaitu membagi *dataset* menjadi dua bagian yang terpisah: data latih (*training data*) dan data uji (*testing data*). Data latih digunakan pada proses pembelajaran dan penyesuaian parameter model, sedangkan data uji digunakan murni untuk menguji ketepatan prediksi pada data baru. Tanpa pemisahan ini, model dapat diuji menggunakan data yang sama dengan data pelatihan sehingga menghasilkan nilai performa yang tampak tinggi tetapi tidak merepresentasikan kemampuan generalisasi.

Dalam tugas klasifikasi, fondasi evaluasi performa model umumnya menggunakan *confusion matrix*, yaitu tabel yang membandingkan label prediksi model dengan label aktual (*ground truth*) pada data uji. *Confusion matrix* terdiri dari empat komponen utama: *True Positive* (TP) ketika model memprediksi kelas positif dengan benar, *True Negative* (TN) ketika model memprediksi kelas negatif dengan benar, *False Positive* (FP) ketika model memprediksi positif padahal aktualnya negatif, dan *False Negative* (FN) ketika model memprediksi negatif padahal aktualnya positif (Tarigan dkk., 2023).

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Gambar 2.7 Ilustrasi *Confusion Matrix*

Sumber Gambar: (Rina, 2023)

Gambar 2.7 menyajikan ilustrasi *confusion matrix* yang menunjukkan perbandingan antara nilai aktual dan nilai prediksi model dalam klasifikasi biner. Matriks ini memetakan empat kemungkinan hasil prediksi, yaitu *True Positive* (TP), *False Positive* (FP), *False Negative* (FN), dan *True Negative* (TN), sehingga memberikan gambaran visual yang jelas mengenai jenis kesalahan yang dilakukan oleh model.

Berdasarkan nilai TP, TN, FP, dan FN, penelitian ini menggunakan metrik evaluasi *accuracy*, *precision*, *recall*, dan *F1-score* untuk menilai performa model (Febrywinata dkk., 2025). Rumus metrik evaluasi tersebut adalah sebagai berikut:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \quad \text{Rumus 5}$$

$$\text{Precision} = \frac{TP}{TP+FP} \quad \text{Rumus 6}$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad \text{Rumus 7}$$

$$F1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad \text{Rumus 8}$$


Accuracy menunjukkan proporsi prediksi benar terhadap seluruh data uji. Namun, agar penilaian lebih seimbang, digunakan *precision* dan *recall*. *Precision* mengukur ketepatan prediksi positif (seberapa banyak prediksi positif yang benar), sedangkan *recall* mengukur kemampuan model dalam menangkap seluruh data

positif aktual. Selanjutnya, *F1-score* digunakan untuk menyeimbangkan *trade-off* antara *precision* dan *recall* melalui rata-rata harmonik keduanya.

Hasil evaluasi melalui *confusion matrix* dan metrik-metrik tersebut menjadi dasar untuk menilai apakah performa model sudah memenuhi kebutuhan penelitian. Jika performa belum optimal, perbaikan dapat dilakukan secara iteratif pada tahap sebelumnya, misalnya pada *text preprocessing*, konfigurasi TF-IDF, atau penyesuaian parameter pelatihan model. Dengan demikian, evaluasi model tidak hanya berfungsi sebagai pelaporan kinerja, tetapi juga sebagai umpan balik untuk meningkatkan kualitas model. Rangkaian proses pengolahan data, pemodelan, hingga evaluasi ini selanjutnya membutuhkan kerangka kerja pengembangan yang terstruktur, yang dibahas pada subbab berikutnya mengenai metodologi CRISP-DM.

2.10. CRISP-DM (*Cross Industry Standard Process for Data Mining*)

Rangkaian proses komputasi yang kompleks, mulai dari pengolahan teks, pembangunan model *machine learning*, hingga tahap evaluasi, menuntut adanya kerangka kerja konseptual yang terstruktur dan sistematis. Dalam disiplin ilmu data dan kecerdasan buatan, salah satu metodologi yang diakui secara luas adalah *Cross Industry Standard Process for Data Mining* (CRISP-DM). Metodologi ini dirancang sebagai standar lintas industri yang independen dari platform atau perangkat lunak tertentu, dengan tujuan memberikan panduan komprehensif dalam pelaksanaan proyek penggalian data. Keberadaan CRISP-DM penting karena berfungsi sebagai kerangka payung yang mengintegrasikan tahapan teknis ke dalam alur kerja logis, sehingga mengurangi risiko kegagalan proyek akibat ketidaksesuaian antara solusi teknis dan tujuan permasalahan (Pernanda dkk., 2023).



Gambar 2.8 Ilustrasi Tahapan Metodologi CRISP-DM

Sumber Gambar: (Alwi, 2024)

Gambar 2.8 menyajikan diagram lingkaran yang mengilustrasikan enam tahapan CRISP-DM beserta hubungan iteratif di antaranya, dengan elemen Data sebagai pusat yang menghubungkan seluruh proses. Diagram ini secara visual menekankan sifat siklus yang tidak linier, di mana setiap tahap dapat memberikan umpan balik (*feedback loop*) ke tahap sebelumnya untuk perbaikan berkelanjutan.

Secara operasional, CRISP-DM terdiri atas enam tahapan utama yang saling berkesinambungan (Pernanda dkk., 2023), yaitu:

1. ***Business Understanding (Pemahaman Bisnis)*** – pendefinisian tujuan proyek, identifikasi konteks permasalahan, serta penentuan kriteria keberhasilan.
2. ***Data Understanding (Pemahaman Data)*** – pengumpulan dan eksplorasi data mentah untuk mengidentifikasi karakteristik serta permasalahan kualitas data.
3. ***Data Preparation (Persiapan Data)*** – pembersihan data, *text preprocessing*, dan rekayasa fitur (*feature engineering*) agar data siap digunakan.

4. **Modeling (Pemodelan)** – pemilihan algoritma, pelatihan model, dan penyesuaian parameter (*tuning*).
5. **Evaluation (Evaluasi)** – peninjauan performa model berdasarkan metrik evaluasi dan kesesuaian dengan tujuan bisnis.
6. **Deployment (Penerapan)** – implementasi solusi ke lingkungan penggunaan, termasuk pemantauan dan pemeliharaan sistem.

Karakteristik penting CRISP-DM yang membedakannya dari pendekatan linier adalah sifatnya yang iteratif. Keenam tahapan tersebut tidak berjalan satu arah secara kaku, melainkan memungkinkan adanya umpan balik dan perbaikan berulang (*feedback loop*). Hasil evaluasi yang kurang memuaskan, misalnya, dapat mengembalikan proses ke tahap pemodelan atau persiapan data untuk perbaikan lebih lanjut.

Adopsi CRISP-DM yang luas menjadikannya kerangka kerja yang umum digunakan dalam berbagai domain karena menyediakan struktur sistematis dan praktik terbaik dalam pengembangan solusi berbasis data. Dalam konteks penelitian berbasis teks seperti sistem rekomendasi resep masakan Indonesia, CRISP-DM sangat relevan karena mampu memetakan proses pengolahan bahasa alami ke dalam alur kerja yang jelas, terutama pada fase *Data Understanding* dan *Data Preparation* yang melibatkan variasi penamaan bahan, ketidakseragaman satuan, serta relasi substitusi bahan yang tidak selalu eksplisit. Oleh karena itu, pemahaman terminologi dan karakteristik data kuliner menjadi landasan penting untuk menerapkan CRISP-DM secara tepat. Pembahasan mengenai konsep dan struktur data resep tersebut akan diuraikan pada subbab berikutnya mengenai Teori Resep.

2.11. Teori Resep

Dalam bidang ilmu komputer dan sistem informasi, sebuah resep masakan tidak hanya dipandang sebagai panduan praktis untuk mengolah makanan, tetapi juga sebagai data yang terstruktur. Secara umum, resep dapat didefinisikan sebagai sekumpulan instruksi terstruktur untuk mengubah sejumlah bahan mentah (*ingredients*) menjadi sebuah hidangan melalui proses memasak tertentu. Ketika resep diolah dalam ranah *Natural Language Processing* (NLP) dan pembelajaran mesin, teks resep perlu diurai dan direpresentasikan secara komputasional agar

mesin dapat memahami, mencocokkan, serta merekomendasikan resep berdasarkan masukan pengguna. Oleh karena itu, pemahaman mengenai struktur dan karakteristik linguistik sebuah resep menjadi landasan penting sebelum sistem rekomendasi dibangun (Mulyawan & Lestari, 2019).

Secara umum, sebuah resep masakan terdiri atas tiga komponen utama. Komponen pertama adalah metadata resep, yang mencakup atribut umum seperti nama hidangan, kategori masakan, takaran porsi (*yield*), waktu persiapan, serta taksiran nilai gizi. Komponen kedua yang paling penting bagi sistem pencocokan adalah daftar bahan (*ingredients list*). Setiap entri pada daftar bahan umumnya mengandung tiga sub-elemen: nama bahan, kuantitas, dan satuan pengukuran (seperti gram, mililiter, atau sendok). Komponen ketiga adalah langkah-langkah pembuatan (*cooking instructions*), yaitu urutan teknik memasak, urutan pencampuran bahan, serta parameter waktu dan suhu (Lestari & Kusriani, 2012). Ketiga komponen inilah yang menjadi sasaran utama dalam proses ekstraksi fitur seperti TF-IDF yang telah dibahas pada subbab sebelumnya.

Meskipun terlihat terstruktur, karakteristik data resep di dunia nyata memiliki tingkat ketidakteraturan dan ketidakpresisian yang tinggi. Berbeda dengan data transaksi finansial atau data sensor yang bersifat pasti, penulisan resep sering kali melibatkan variasi penamaan bahan, yaitu satu bahan yang sama dapat ditulis dengan berbagai istilah lokal. Selain itu, terdapat banyak ketidakkonsistenan dalam penggunaan satuan ukur, seperti istilah "secukupnya", "sejumput", atau "segenggam" yang sulit dikuantifikasi ke dalam bentuk angka baku. Resep juga memiliki sifat fleksibilitas substitusi, yaitu ketiadaan satu bahan sering kali dapat digantikan oleh bahan lain yang memiliki fungsi serupa tanpa mengubah hasil masakan secara berarti (Wong & Yoannita, 2026).

Untuk mengatasi kompleksitas tersebut, diperlukan pendekatan pemodelan yang dikenal sebagai ontologi kuliner (*culinary ontology*). Ontologi kuliner adalah kerangka hierarkis yang memetakan hubungan antarbahan masakan, klasifikasi teknik memasak, serta atribut rasa dan tekstur. Melalui ontologi ini, mesin tidak hanya melihat kata "bawang merah" dan "bawang putih" sebagai dua kata yang berbeda, tetapi dapat mengenali keduanya berada dalam kelompok hierarki yang

sama, yaitu keluarga *Allium*. Pemetaan hubungan substitusi dan saling melengkapi antarbahan inilah yang penting diterapkan dalam sistem rekomendasi, agar rekomendasi yang dihasilkan tetap logis dan relevan dengan ketersediaan bahan pengguna (Mulyawan & Lestari, 2019).

Karakteristik teks resep yang banyak mengandung konteks implisit dan keunikan bentuk kata ini menegaskan pentingnya penerapan *text preprocessing* yang tepat. Tantangan dalam merepresentasikan variasi takaran dan penamaan lokal menuntut adanya normalisasi istilah sebelum vektor TF-IDF dihitung. Tanpa pemahaman yang cukup mengenai sifat dasar resep, algoritma *machine learning* berpotensi gagal menangkap makna di balik instruksi memasak. Oleh karena itu, perlakuan resep sebagai *dataset* perlu diselaraskan dengan alur kerja CRISP-DM, mulai dari tahap *data understanding* untuk memahami keragaman teks kuliner, hingga *data preparation* untuk menstandarkan format masukannya.

Setelah landasan teori mengenai pengolahan teks, algoritma klasifikasi, evaluasi model, hingga struktur data resep dipahami, tahapan selanjutnya adalah merancang arsitektur implementasinya. Model yang telah dilatih tidak dapat berdiri sendiri; model tersebut membutuhkan lingkungan operasional agar dapat berinteraksi dengan pengguna akhir. Proses transisi dari model menjadi purwarupa perangkat lunak yang berfungsi ini membutuhkan dukungan infrastruktur dan kerangka kerja antarmuka yang memadai. Konsep, peran, dan arsitektur perangkat lunak pengembangan (*web framework*) yang memfasilitasi penerapan (*deployment*) model ini akan dibahas pada subbab terakhir mengenai Framework Web.


2.12. Framework Web

Setelah rangkaian komputasi penelitian, mulai dari pemrosesan teks resep, ekstraksi fitur ke dalam representasi numerik, hingga pelatihan model *machine learning* selesai dibangun, model yang dihasilkan memerlukan lingkungan operasional agar dapat diakses oleh pengguna akhir. Dalam rekayasa perangkat lunak modern, kebutuhan tersebut umumnya difasilitasi melalui *web framework*. Secara definisi, *web framework* merupakan abstraksi perangkat lunak yang menyediakan infrastruktur, pustaka dasar (*libraries*), serta pola struktur pengembangan yang baku untuk membangun dan memelihara aplikasi web

interaktif. Penggunaan *web framework* bertujuan untuk mengurangi pekerjaan pengembangan yang berulang, mempercepat proses penerapan (*deployment*), serta menerapkan prinsip *separation of concerns* (pemisahan tanggung jawab) antara pengelolaan data, logika bisnis, dan antarmuka pengguna (Rahmadani dkk., 2024).

Dalam arsitektur aplikasi web saat ini, ekosistem pengembangan umumnya terbagi menjadi tiga komponen utama, yaitu *backend*, *frontend*, dan *database*. *Backend* bertugas menangani logika operasional di sisi peladen (*server-side logic*), termasuk pengelolaan rute layanan, otorisasi, keamanan, dan penyediaan *endpoint*. *Frontend* merupakan lapisan presentasi visual yang berinteraksi langsung dengan pengguna (*client-side logic*). Sementara itu, *database* berfungsi sebagai media penyimpanan data persisten, seperti data resep, riwayat pencarian, dan informasi sesi pengguna.

Integrasi ketiga komponen tersebut umumnya diimplementasikan menggunakan arsitektur *client-server* melalui mekanisme *request-response*. Salah satu pola desain yang paling umum digunakan dalam *web framework* adalah pola MVC (*Model-View-Controller*).



Gambar 2.9 Ilustrasi Pola MVC pada *Web Framework*

Sumber Gambar: (GeeksforGeeks, 2026)

Gambar 2.9 mengilustrasikan pola MVC (*Model-View-Controller*) yang menjadi fondasi banyak *web framework*. Diagram ini menunjukkan alur kerja dari *request* pengguna hingga *response* yang dikembalikan, dengan *Controller* sebagai

pengatur utama, *Model* sebagai lapisan abstraksi data, dan *View* sebagai antarmuka yang ditampilkan kepada pengguna.

Sejalan dengan gambar tersebut, proses diawali ketika pengguna mengirim *request* melalui protokol HTTP. Permintaan tersebut dipetakan oleh modul perutean (*routing*) menuju *controller*, yang kemudian memanggil *model* untuk mengolah logika bisnis dan berinteraksi dengan *database*. Setelah pemrosesan selesai, *controller* menyusun *response* dan mengirimkannya kembali ke *view* untuk ditampilkan pada antarmuka pengguna. Pola ini memungkinkan pemisahan tanggung jawab yang jelas, sehingga memudahkan pengembangan dan pemeliharaan sistem.

Salah satu contoh *web framework* yang ringan dan populer adalah Flask (berbasis Python). Flask sering digunakan dalam proyek berbasis *machine learning* karena fleksibilitasnya yang tinggi, ukuran yang kecil, serta kemudahan dalam mengintegrasikan model *Artificial Neural Network* dan *deployment* ke lingkungan produksi (Rahmadani dkk., 2024).

Selain mengatur alur *request-response*, *web framework* yang baik juga mendukung aspek non-fungsional, seperti *scalability* (kemampuan menangani akses simultan), *security* (perlindungan terhadap serangan), serta *maintainability* (kemudahan pemeliharaan). Dengan demikian, *web framework* berperan penting untuk menjembatani model analitik yang bersifat teoretis agar dapat diterapkan menjadi sistem yang dapat digunakan secara nyata oleh pengguna.


Secara keseluruhan, uraian teoretis pada BAB II mulai dari kecerdasan buatan, *Artificial Neural Networks*, *Natural Language Processing* (NLP), ekstraksi fitur TF-IDF dan *cosine similarity*, metodologi CRISP-DM, hingga *web framework* membangun landasan konseptual bagi implementasi sistem pada penelitian ini. Setelah fondasi tersebut dipaparkan, pembahasan selanjutnya akan beralih dari ranah teoretis (*what and why*) menuju ranah implementatif (*how*). Oleh karena itu, detail arsitektur penerapan, skema pembangunan aplikasi, mekanisme pelatihan model, serta tahapan metodologi penelitian akan diuraikan pada BAB III.

BAB III

METODOLOGI PENELITIAN

Penelitian ini dilaksanakan menggunakan kerangka kerja *Cross Industry Standard Process for Data Mining* (CRISP-DM), yaitu metodologi terstruktur yang umum diterapkan pada pengembangan sistem berbasis *machine learning* dan penambangan teks (*text mining*) (Pernanda dkk., 2023). Pendekatan ini dipilih untuk menjaga agar alur pengembangan sistem rekomendasi tetap sistematis dan terukur, mulai dari pemahaman masalah hingga penerapan model ke lingkungan nyata. Secara teknis, sistem yang dibangun memadukan dua metode utama, yaitu algoritma *Artificial Neural Network* (ANN) yang berperan mengklasifikasikan teks bahan masukan ke dalam kategori resep, serta *Cosine Similarity* yang berperan mengukur dan memeringkat kemiripan resep guna menghasilkan rekomendasi akhir yang relevan.

Metodologi CRISP-DM yang diterapkan pada penelitian ini meliputi enam fase utama yang saling berkesinambungan, yaitu *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment*. Keenam fase tersebut tidak selalu berjalan satu arah, melainkan dapat bersifat iteratif apabila hasil evaluasi menuntut perbaikan pada tahap pemodelan. Keseluruhan alur kerja tahapan tersebut divisualisasikan pada Gambar 3.1 berikut.



Gambar 3.1 Flowchart Alur Penelitian

Berdasarkan Gambar 3.1, penelitian diawali pada tahap *Business Understanding* untuk mengidentifikasi masalah dan merumuskan tujuan sistem. Tahap berikutnya, *Data Understanding*, berfokus pada pengumpulan dan analisis awal dataset resep masakan yang digunakan. Data tersebut kemudian dibersihkan dan ditransformasikan pada tahap *Data Preparation* hingga siap diproses oleh model. Selanjutnya, pada tahap *Modeling*, algoritma ANN dilatih untuk mengklasifikasikan kategori resep dan dipadukan dengan *Cosine Similarity* untuk memeringkat rekomendasi. Kinerja model lalu diukur pada tahap *Evaluation*; apabila hasilnya belum optimal, proses dapat kembali ke tahap pemodelan untuk penyempurnaan. Terakhir, model yang telah teruji diintegrasikan ke dalam antarmuka sistem berbasis web pada tahap *Deployment* agar dapat digunakan oleh pengguna.

3.1. Pemahaman Masalah dan Tujuan (*Business Understanding*)

Fase pertama dalam metodologi CRISP-DM adalah *Business Understanding*. Pada tahap ini, pemahaman terhadap masalah dibangun melalui studi literatur. Langkah awal difokuskan pada identifikasi masalah (*problem identification*) dengan mempelajari berbagai penelitian terdahulu mengenai sistem rekomendasi pemanfaatan bahan makanan. Dari kajian tersebut, teridentifikasi bahwa meskipun beberapa penelitian telah mengembangkan fitur penyaringan resep berbasis bahan, pendekatan komputasi yang digunakan umumnya masih memiliki keterbatasan. Beberapa metode pengenalan bahan, seperti yang berbasis pengolahan citra, menuntut sumber daya komputasi yang besar (Saputri dkk., 2024; Rahmawan dkk., 2022), sementara sebagian metode klasifikasi berbasis teks lainnya belum optimal dalam menangani keragaman teks bahan masakan Indonesia (Febrywinata dkk., 2025). Oleh karena itu, ditemukan celah penelitian (*gap analysis*) untuk menghadirkan solusi yang lebih ringan secara komputasi. Berdasarkan celah tersebut, tujuan penelitian (*business objective*) dirumuskan untuk membangun sistem cerdas menggunakan algoritma *Artificial Neural Network* (ANN). Algoritma ini dipilih karena memiliki kemampuan mengenali pola non-linear dan hubungan kompleks pada data teks berdimensi tinggi, sehingga sesuai untuk mengklasifikasikan keragaman teks bahan masakan Indonesia. Sistem ini bertujuan

untuk memproses teks masukan bahan dari pengguna secara langsung guna memberikan rekomendasi resep masakan Indonesia secara presisi dan efisien.

Setelah masalah dipahami, langkah selanjutnya adalah menilai situasi (*situation assessment*) terkait ketersediaan data pendukung. Pada tahap ini, dilakukan eksplorasi dan pemanfaatan dataset sekunder publik dari platform Kaggle, yaitu *Indonesian Food Recipes Dataset* (Nathaniel, 2024). Dataset yang berisi ribuan teks resep dan komposisi bahan ini digunakan sebagai fondasi utama penentuan batasan penelitian. Kesimpulan dari permasalahan pada literatur yang dipadukan dengan ketersediaan data ini kemudian dirumuskan menjadi sasaran teknis penelitian (*data mining goal*). Berdasarkan sasaran tersebut, disusunlah rencana proyek (*project plan*) yang berfokus pada penerapan pemrosesan bahasa alami untuk mengekstraksi data teks, melatih model ANN sebagai pengklasifikasi kategori resep, serta menerapkan *Cosine Similarity* untuk memeringkat kemiripan resep, yang keberhasilannya kemudian diukur menggunakan metrik evaluasi yang telah ditentukan untuk menilai kinerja sistem.

3.2. Pemahaman Data (*Data Understanding*)

Fase pemahaman data berfokus pada identifikasi, pengumpulan, dan analisis karakteristik dataset awal yang digunakan untuk melatih model. Data dalam penelitian ini merupakan dataset sekunder publik yang diperoleh melalui platform Kaggle dengan judul *Indonesian Food Recipes Dataset* (Nathaniel, 2024). Berdasarkan tinjauan statistik awal, dataset ini memuat 14.945 baris data resep dan terdiri dari 10 kolom atribut. Data tersebut terbagi ke dalam delapan kelas bahan utama, yaitu udang (1.994), tempe (1.956), sapi (1.920), telur (1.902), kambing (1.874), ikan (1.863), ayam (1.803), dan tahu (1.633). Distribusi antar kelas tergolong relatif seimbang (rentang 1.633–1.994 atau rasio sekitar 1,2:1), sehingga dataset dinilai representatif untuk pelatihan model klasifikasi. Sebagai bagian dari analisis awal, dilakukan pula verifikasi kualitas data untuk memastikan tidak terdapat nilai kosong (*null*) maupun duplikasi pada atribut utama yang akan digunakan.

Dari sepuluh kolom yang tersedia (*Title*, *Ingredients*, *Steps*, *Category*, *URL*, *Loves*, *Total Ingredients*, *Total Steps*, *Ingredients Cleaned*, dan *Title Cleaned*),

tidak seluruhnya relevan untuk pemodelan. Kolom seperti *URL*, *Loves*, *Total Ingredients*, dan *Total Steps* merupakan metadata pelengkap yang tidak digunakan dalam proses klasifikasi. Dataset juga menyediakan kolom turunan, yaitu *Ingredients Cleaned* dan *Title Cleaned*, yang sebagian telah dibersihkan sebelumnya. Namun, penelitian ini memilih untuk mengolah atribut *Ingredients* mentah secara mandiri melalui tahapan prapemrosesan yang dirancang sendiri, agar seluruh proses transformasi data terkontrol dan transparan secara metodologis. Dengan demikian, penelitian ini menyeleksi empat atribut utama yang paling relevan dengan arsitektur algoritma *Artificial Neural Network* (ANN) yang akan dibangun. Gambaran detail struktur dan fungsi atribut tersebut dapat dilihat pada Tabel 3.1.

Tabel 3.1 Struktur dan Kategori Atribut Utama Dataset


No	Atribut / Kolom	Tipe Data	Kategori	Keterangan
1	<i>Title</i>	Teks	Identitas	Judul atau nama spesifik resep masakan Indonesia. Berfungsi sebagai identitas/nama resep yang ditampilkan sebagai hasil rekomendasi akhir (output sistem).
2	<i>Ingredients</i>	Teks	Fitur (<i>Input</i>)	Kumpulan bahan tak terstruktur dari setiap resep; menjadi fokus utama yang diekstraksi menjadi bobot numerik menggunakan TF-IDF sebagai masukan model.
3	<i>Category</i>	Kategorikal (8 kelas)	Label/Target	Kelas bahan utama resep (ayam, ikan, kambing, sapi, tahu, telur, tempe, udang). Menjadi label/target yang diprediksi oleh model ANN.
4	<i>Steps</i>	Teks	Informasi Tambahan	Tata cara memasak; tidak dilibatkan dalam pelatihan model, hanya ditampilkan pada antarmuka sebagai panduan bagi pengguna.

Berdasarkan pemetaan pada Tabel 3.1, atribut *Ingredients* memainkan peran sentral sebagai data masukan utama yang akan diproses lebih lanjut pada tahap

prapemrosesan teks. Atribut *Category* berperan sebagai label/target klasifikasi yang akan diprediksi oleh model ANN ke dalam delapan kelas bahan utama. Sementara itu, atribut *Title* bukan merupakan target model, melainkan identitas keluaran—yakni nama resep yang ditampilkan kepada pengguna setelah proses pemeringkatan dengan *Cosine Similarity*. Adapun atribut *Steps* tidak dilibatkan dalam pelatihan model, melainkan dipanggil dari basis data untuk ditampilkan pada antarmuka akhir sebagai panduan praktis memasak bagi pengguna.

3.3. Persiapan Data (*Data Preparation*)

Fase persiapan data (*Data Preparation*) bertujuan untuk membersihkan dan mentransformasikan data mentah menjadi format numerik yang siap diproses oleh algoritma komputasi. Pada penelitian ini, tahap persiapan data difokuskan secara mendalam pada pemrosesan teks (*text processing*) untuk atribut *Ingredients* (daftar bahan masakan), mengingat *Artificial Neural Network* (ANN) hanya dapat memproses masukan berupa data numerik. Tahapan yang direncanakan pada fase ini meliputi prapemrosesan teks, pembagian dataset, dan ekstraksi fitur. Rencana alur persiapan data tersebut divisualisasikan pada Gambar 3.2.



Gambar 3.2 Flowchart Tahapan Persiapan Data

Berdasarkan Gambar 3.2, tahapan secara rinci akan dilakukan sebagai berikut:

1. Prapemrosesan Teks (*Text Preprocessing*)

Proses ini bertujuan menghilangkan gangguan (*noise*) pada teks bahasa Indonesia. Rangkaian prapemrosesan ini memanfaatkan pustaka pemrosesan bahasa alami (*Natural Language Processing/NLP*), di antaranya pustaka **Sastrawi** untuk penanganan *stopword* dan *stemming* bahasa Indonesia, melalui tahapan:

- a) **Filtering**: Pembersihan data dengan menghapus angka, tanda baca, serta karakter khusus yang tidak relevan. Proses ini penting untuk menghilangkan unsur ukuran (seperti "500gr" atau "1/2") agar sistem hanya berfokus pada nama bahan masakan.
- b) **Case Folding**: Mengubah seluruh huruf menjadi huruf kecil (*lowercase*) untuk menyeragamkan format karakter.
- c) **Tokenizing**: Memecah teks daftar bahan masakan menjadi potongan-potongan kata tunggal (*token*) agar dapat diproses secara individual pada tahap selanjutnya.
- d) **Stopword Removal**: Menghapus kata-kata yang tidak memiliki nilai klasifikasi yang kuat, seperti kata hubung dan kata takaran umum (contoh: "dan", "secukupnya"), termasuk satuan ukuran (seperti "gr", "gram", "kg", "ml", "sdm", "sdt", "butir", "siung", "lembar").
- e) **Stemming**: Mengubah kata berimbuhan menjadi kata dasar baku sesuai tata bahasa Indonesia menggunakan pustaka Sastrawi, sehingga variasi kata yang bermakna sama dapat disatukan.

2. Pembagian Data (*Data Splitting*)

Sebelum ekstraksi fitur, dataset dibagi terlebih dahulu menjadi dua bagian terpisah untuk kebutuhan pelatihan dan pengujian model. Pembagian dilakukan lebih awal untuk mencegah kebocoran data (*data leakage*), yaitu agar informasi dari data uji tidak ikut memengaruhi pembentukan fitur. Penelitian ini menggunakan rasio pembagian 80:20, yaitu 80% dari total data (11.956 baris) sebagai data latih (*training data*) untuk membangun pola pada model ANN, dan 20% sisanya (2.989

baris) sebagai data uji (*testing data*) untuk mengukur kemampuan prediksi model terhadap data yang belum pernah dilihat sebelumnya.

3. Ekstraksi Fitur dengan TF-IDF


Setelah data terbagi, teks bersih hasil prapemrosesan diubah menjadi representasi numerik menggunakan metode *Term Frequency–Inverse Document Frequency* (TF-IDF). Metode ini menghitung bobot statistik setiap kata dasar bahan: semakin sering sebuah bahan muncul pada satu resep namun jarang muncul di seluruh kumpulan resep, semakin tinggi bobot uniknya. Proses pembentukan TF-IDF (*fit*) dilakukan hanya pada data latih untuk menghasilkan kosakata dan bobot IDF; representasi (*transform*) data uji kemudian dilakukan menggunakan parameter yang sama agar konsisten dan bebas dari kebocoran data. Hasil akhir tahap ini adalah transformasi data dari format teks menjadi matriks vektor numerik, yang menjadi masukan bagi model ANN sekaligus dasar perhitungan kemiripan *Cosine Similarity* pada tahap rekomendasi.

3.4. Pemodelan (*Modeling*)

Fase keempat dalam CRISP-DM adalah pemodelan (*Modeling*), yaitu tahapan inti tempat algoritma *machine learning* dibangun dan dilatih menggunakan data yang telah dipersiapkan sebelumnya. Penelitian ini membangun model menggunakan algoritma *Artificial Neural Network* (ANN), yang dipilih karena kemampuannya mengenali pola non-linear dan hubungan kompleks pada data teks berdimensi tinggi—sesuai dengan kebutuhan untuk mengklasifikasikan daftar bahan masakan (*input*) ke dalam kategori resep (*output* klasifikasi). Pada tahap ini, matriks vektor numerik hasil ekstraksi TF-IDF dimasukkan ke dalam *Input Layer* (lapisan masukan) arsitektur jaringan. Jumlah *node* atau neuron pada *Input Layer* menyesuaikan dengan jumlah fitur kata (bahan masakan) unik yang dihasilkan pada tahap prapemrosesan.

Selanjutnya, informasi dari *Input Layer* diteruskan ke *Hidden Layer* (lapisan tersembunyi) untuk proses penyetelan bobot selama pelatihan. Sebagai rancangan awal (*baseline*), arsitektur ANN ini direncanakan menggunakan dua tingkat *Hidden Layer*. Untuk menghindari masalah gradien yang hilang (*vanishing gradient*) dan mempercepat konvergensi pembelajaran, kedua *Hidden Layer* tersebut

menggunakan fungsi aktivasi *Rectified Linear Unit* (ReLU). Setelah pola dikenali, hasil komputasi diteruskan ke *Output Layer* (lapisan keluaran) yang terdiri atas delapan *node* sesuai delapan kategori bahan utama (ayam, ikan, kambing, sapi, tahu, telur, tempe, dan udang). *Output Layer* menggunakan fungsi aktivasi Softmax untuk menghasilkan distribusi probabilitas atas kedelapan kategori tersebut, sehingga sistem dapat menentukan kategori yang paling sesuai dengan bahan masukan pengguna. Rancangan awal arsitektur pemodelan ANN tersebut diilustrasikan pada Gambar 3.3.



Gambar 3.3 Rancangan Awal Arsitektur *Artificial Neural Network* (ANN)

Berdasarkan Gambar 3.3, alur pemodelan secara hierarkis dimulai dengan menerima data masukan pada *Input Layer*. Data tersebut kemudian diproses melalui serangkaian lapisan komputasi di dalam *Hidden Layer*. Pada rancangan ini digunakan dua tingkat *Hidden Layer* yang bertugas secara berurutan mengekstraksi fitur komputasional dan mengenali pola kompleks dari kombinasi bahan masakan. Setelah melalui proses penyetelan bobot di dalam *Hidden Layer*, hasil komputasi diteruskan ke *Output Layer*, yang mengonversi perhitungan jaringan menjadi distribusi probabilitas atas delapan kategori resep.

Perlu ditegaskan bahwa keluaran ANN berupa prediksi kategori belum merupakan rekomendasi akhir. Setelah model menentukan kategori bahan utama, sistem melanjutkan ke tahap pemeringkatan menggunakan *Cosine Similarity*. Pada tahap ini, vektor TF-IDF dari bahan masukan pengguna dibandingkan tingkat kemiripannya dengan vektor seluruh resep yang berada di dalam kategori hasil prediksi ANN. Resep dengan nilai kemiripan tertinggi kemudian diurutkan dan ditampilkan sebagai rekomendasi akhir (*Top-N*). Dengan demikian, ANN berperan mempersempit ruang pencarian ke satu kategori yang relevan, sementara *Cosine Similarity* menentukan resep spesifik yang paling sesuai dengan ketersediaan bahan pengguna.

3.5. Evaluasi (*Evaluation*)

Fase kelima dalam metodologi CRISP-DM adalah Evaluasi (*Evaluation*). Pada tahap ini, kinerja dan keandalan model *Artificial Neural Network* (ANN) yang telah dilatih diukur secara komprehensif. Proses evaluasi menggunakan 20% data uji (*testing data*) yang sebelumnya disisihkan pada tahap persiapan data. Penggunaan data uji yang belum pernah dilihat model selama pelatihan ini krusial untuk memastikan model tidak sekadar menghafal pola (*overfitting*), melainkan benar-benar memiliki kemampuan generalisasi yang baik dalam mengklasifikasikan kategori bahan utama dari masukan yang baru.

Untuk mengukur keakuratan model dalam mengklasifikasikan kategori resep, penelitian ini menggunakan pendekatan *Confusion Matrix*. Karena klasifikasi ini bersifat multikelas (delapan kategori), *Confusion Matrix* yang terbentuk berukuran 8×8 , dan setiap metrik dihitung per kategori berdasarkan komponen *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN), kemudian dirata-ratakan (*macro/weighted average*) untuk memperoleh nilai keseluruhan. Metrik evaluasi yang dihitung meliputi Akurasi, Presisi, *Recall*, dan *F1-Score*, dengan rincian sebagai berikut:

1. Akurasi (*Accuracy*)

Akurasi merupakan rasio prediksi yang benar secara keseluruhan dibandingkan dengan total data yang diuji. Metrik ini menunjukkan seberapa tepat model mengklasifikasikan kategori secara umum.

2. Presisi (*Precision*)

Presisi mengukur ketepatan prediksi positif model. Dalam konteks ini, dari seluruh resep yang diprediksi masuk ke suatu kategori, presisi menunjukkan proporsi resep yang benar-benar milik kategori tersebut.

3. *Recall* (Sensitivitas)

Recall mengukur kemampuan model menemukan kembali seluruh anggota suatu kategori. Metrik ini menunjukkan, dari seluruh resep yang sebenarnya milik suatu kategori, berapa proporsi yang berhasil diprediksi dengan benar oleh model.

4. *F1-Score*

F1-Score merupakan rata-rata harmonik dari Presisi dan *Recall*. Mengingat distribusi data antar kategori relatif seimbang (rasio $\pm 1,2:1$), Akurasi tetap menjadi metrik yang andal; sementara itu, *F1-Score* digunakan untuk memastikan keseimbangan antara Presisi dan *Recall* tetap terjaga secara merata di seluruh kategori.

3.6. Penyebaran (*Deployment*)

Fase keenam sekaligus terakhir dari metodologi CRISP-DM adalah penyebaran (*Deployment*). Pada tahapan ini, model *Artificial Neural Network* (ANN) beserta *vectorizer* TF-IDF yang telah dilatih dan terbukti memiliki performa terbaik pada tahap evaluasi akan diekspor dan disimpan ke dalam format *file* yang siap pakai. Model analitik hasil pelatihan tersebut kemudian dioperasikan dengan cara diintegrasikan ke dalam lingkungan sistem nyata berupa aplikasi berbasis web. Berdasarkan rancangan sistem, proses integrasi dan *deployment* ini direncanakan memanfaatkan *web framework* Flask yang berbasis bahasa pemrograman Python. *Framework* ini dipilih karena sifatnya yang ringan, fleksibel, serta andal dalam menjembatani dan mengelola *deployment* model *machine learning* ke lingkungan produksi.

Secara operasional, skenario penyebaran ini memisahkan tanggung jawab antara *backend* (peladen) dan *frontend* (antarmuka pengguna). Pengguna akhir berinteraksi dengan sistem melalui antarmuka web dengan memasukkan daftar bahan makanan yang tersedia di dapur. Data teks tersebut kemudian dikirim ke *backend* untuk diproses: setelah melalui prapemrosesan dan ekstraksi fitur, model

ANN mengklasifikasikan masukan ke dalam salah satu kategori bahan utama. Selanjutnya, Cosine Similarity memeringkat resep-resep di dalam kategori tersebut berdasarkan tingkat kemiripan bahan dengan masukan pengguna. Sistem kemudian merespons dengan mengirimkan keluaran berupa rekomendasi resep masakan Indonesia (*Top-N*) yang paling relevan, lengkap dengan bahan dan langkah pembuatannya, untuk ditampilkan secara visual di layar pengguna.

DAFTAR PUSTAKA

- Alfin, M., Akbar, M. B., Manik, A. R., Purba, J., & Perdana, A. (2025). PENGEMBANGAN APLIKASI REKOMENDASI RESEP MAKANAN BERDASARKAN BAHAN MENGGUNAKAN API. *JATI (Jurnal Mahasiswa Teknik Informatika)*.
- Alwi, M. N. (2024, Juni 19). *CRISP-DM: Tahapan, Studi Kasus, Kelebihan, dan Kekurangan*. <https://www.dicoding.com/blog/crisp-dm-tahapan-studi-kasus-kelebihan-dan-kekurangan/>
- Ananda, I. K. N., Dewi, N. P. N. P., Marti, N. W., & Dewi, L. J. E. (2024). Klasifikasi Multilabel Pada Gaya Belajar Siswa Sekolah Dasar Menggunakan Algoritma Machine Learning. *Journal of Applied Computer Science and Technology*, 5(2), 144–154. <https://doi.org/10.52158/jacost.v5i2.940>
- Bre, F., Gimenez, J. M., & Fachinotti, V. D. (2018). Prediction of wind pressure coefficients on building surfaces using artificial neural networks. *Energy and Buildings*, 158, 1429–1441. <https://doi.org/10.1016/j.enbuild.2017.11.045>
- Descania, D. Y. (2022). Prediksi Pertumbuhan Penduduk Di Kecamatan Baregbeg Kabupaten Ciamis Menggunakan Metode Artificial Neural Network. *Jurnal Informatika dan Teknologi Pendidikan*, 2(2), 37–43. <https://doi.org/10.25008/jitp.v2i2.28>
- Faiz, A. I., & Ridhwanullah, D. (2025). SAVORYAI: SISTEM REKOMENDASI RESEP MASAKAN BERBASIS CONTENT-BASED FILTERING DAN OPENAI API. *Jurnal TIKomSiN*, 13(2). <https://doi.org/10.30646/tikomsin.v13i2.1023>
- Febrywinata, E., Az-Zahra, R. R., & Nurfitri, K. (2025). Sistem Rekomendasi Masakan Berdasarkan Ketersediaan Bahan Menggunakan Metode Content-Based Filtering dengan Algoritma K-Nearest Neighbors. *Jurnal Teknik Informatika dan Teknologi Informasi*, 5(2), 757–772. <https://doi.org/10.55606/jutiti.v5i2.5690>
- Firmansyah, M. F. (2025, November 28). *Memahami Binary Classification dalam Deep Learning*. <https://medium.com/@fiqrif/memahami-binary-classification-dalam-deep-learning-7e00beecc8d1>
- geeksforgeeks. (2026, Mei 18). *MVC Design Pattern*. <https://www.geeksforgeeks.org/system-design/mvc-design-pattern/>
- Hanum, A. R., Pramukantoro, E. S., & Kartikasari, D. P. (2025). STUDI PERBANDINGAN KINERJA TF-IDF DAN INDOBERT UNTUK REKOMENDASI RESEP BERDASARKAN KETERSEDIAAN BAHAN MAKANAN BERBASIS WEBSITE. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*. <http://j-ptiik.ub.ac.id>

- Lestari, S. Y., & Kusriani. (2012). MEMBANGUN APLIKASI MOBILE “RESEP MASAKAN ASIA (INDONESIA, CHINA, JEPANG)” BERBASIS ANDROID. *JURNAL DASI*.
- Maulid, R. (2023, November 28). *Content Based Filtering dalam Algoritma Data Science*. <https://dqlab.id/content-based-filtering-dalam-algoritma-data-science>
- Mulyawan, Y. R., & Lestari, C. C. (2019). RANCANG BANGUN SISTEM REKOMENDASI RESEP MASAKAN BERDASARKAN BAHAN BAKU DENGAN MENGGUNAKAN ALGORITMA PENYARINGAN BERBASIS KONTEN. Dalam *JUTI: Jurnal Ilmiah Teknologi Informasi* (Vol. 17, Nomor 2).
- Nathaniel, A. (2024, Juni 21). *Indonesian Food Recipes Dataset [Data set]*. Kaggle. <https://www.kaggle.com/datasets/albertnathaniel12/food-recipes-dataset>
- Pernanda, S. T., Lavindi, E. E., Yobioktabera, A., & Karima, A. (2023). *IMPLEMENTASI CRISP-DM PADA SISTEM REKOMENDASI BERBASIS KONTEN UNTUK PENENTUAN JENIS IKAN HIAS DALAM AKUARIUM* (Vol. 19, Nomor 3).
- Purwitasari, N. A., & Soleh, M. (2022). *Implementasi Algoritma Artificial Neural Network Dalam Pembuatan Chatbot Menggunakan Pendekatan Natural Language Processing*. <https://doi.org/https://doi.org/10.31543/jii.v6i1.192>
- Rahmadani, N. F., Agustina, N. A., Robbayani, W. H., & Ardiyanto, M. (2024). *Sistem Informasi Penjualan Baju Adat Jawa “Busana Keraton” Berbasis Web Menggunakan Flask Python*.
- Rahmadden, R., Anam, M. K., Irawan, Y., Susanti, S., & Jamaris, M. (2022, April 30). *Comparison of Support Vector Machine and XGBSVM in Analyzing Public Opinion on Covid-19 Vaccination*. *ILKOM Jurnal Ilmiah*. <https://doi.org/10.33096/ilkom.v14i1.1090.32-38>
- Rahmawan, A. R., Wicaksana, C. A., & Alimuddin. (2022). APLIKASI PENDETEKSI MAKANAN DAN REKOMENDASI RESEP MASAKAN KHAS INDONESIA. *Jurnal Ilmiah Setrum*, 11(1), 158–168. <https://doi.org/10.36055/setrum.v11i1.15919>
- Rina. (2023, Juni 11). *Memahami Confusion Matrix: Accuracy, Precision, Recall, Specificity, dan F1-Score untuk Evaluasi Model Klasifikasi*. <https://esairina.medium.com/memahami-confusion-matrix-accuracy-precision-recall-specificity-dan-f1-score-610d4f0db7cf>
- Saputri, B. R. D., Asmawati, F. D., Rahmawati, A., Manggala, I. H., & Hidayattullah, M. F. (2024). DETEKSI BAHAN MAKANAN UNTUK REKOMENDASI RESEP MASAKAN PADA PROGRAM DIET

- MENGGUNAKAN ALGORITMA CNN. *Jurnal Ilmiah Informatika (Scientific Informatics Journal)*.
- Shivanandhan, M. (2025, September 10). *Cosine Similarity Explained: The Math Behind LLMs*. <https://medium.com/data-science-collective/cosine-similarity-explained-the-math-behind-llms-b20caac9f93c>
- Sholikhah, Q. M., & Asmunin. (2020). Sistem Rekomendasi Resep Makanan Dengan Metode Collaborative Filtering Dan FP-Growth Menggunakan API themebdb.com. *JINACS: Journal of Informatics and Computer Science*.
- Tarigan, I. D. S., Habibi, R., & Fatonah, Rd. N. S. (2023). Evaluasi Algoritma Klasifikasi Machine Learning Kategori Nilai Akhir Tunjangan Kinerja Pegawai. Dalam *Jurnal Sistem Cerdas* (Vol. 6, Nomor 3).
- Tuntas, R., & Dikici, B. (2016). An investigation on the aging responses and corrosion behaviour of A356/SiC composites by neural network: The effect of cold working ratio. *Journal of Composite Materials*, 50(17), 2323–2335. <https://doi.org/10.1177/0021998315602950>
- Wahyuni, V., Niswatin, R. K., & Hariri, F. R. (2018). *Sistem Rekomendasi Resep Masakan Menggunakan Kombinasi Metode ROC dan SAW*.
- Wong, J., & Yoannita. (2026). IMPLEMENTASI TF-IDF DAN COSINE SIMILARITY UNTUK REKOMENDASI RESEP MASAKAN INDONESIA BERDASARKAN BAHAN MAKANAN. Dalam *Jurnal Mahasiswa Teknik Informatika* (Vol. 10, Nomor 1).